analisis-exploratorio-de-datos

October 29, 2024

1 Presentación: Gestión de Proyectos y Metodologías Ágiles en Data Science

1.1 Introducción

¡Bienvenidos a esta sesión dedicada a la gestión de proyectos y metodologías ágiles en el campo de Data Science! En este espacio, exploraremos cómo aplicar principios de gestión de proyectos y metodologías ágiles para llevar a cabo proyectos de análisis de datos de manera efectiva y colaborativa.

1.2 ¿Qué es la Gestión de Proyectos?

La gestión de proyectos es el proceso de planificación, organización, dirección y control de los recursos para lograr un objetivo específico dentro de un plazo establecido. En el contexto de Data Science, la gestión de proyectos implica coordinar equipos multidisciplinarios para analizar datos y generar insights que impulsen la toma de decisiones informadas.

1.2.1 Componentes de la Gestión de Proyectos:

1. **Planificación**: Comprende la definición de objetivos claros, la identificación de recursos necesarios y la estimación de tiempos y costos. Por ejemplo, al planificar un proyecto de análisis de datos para una empresa de comercio electrónico, se pueden establecer objetivos como mejorar la segmentación de clientes y aumentar las ventas.
2. **Ejecución**: Implica la implementación del plan definido, asignación de tareas y coordinación de actividades del equipo. Durante esta etapa, es importante mantener una comunicación abierta y fluida para garantizar que el trabajo se realice de manera efectiva. Por ejemplo, el equipo de Data Science puede trabajar en estrecha colaboración con el equipo de marketing para recopilar datos y desarrollar modelos predictivos.
3. **Seguimiento y Control**: Consiste en monitorear el progreso del proyecto, identificar desviaciones y tomar medidas correctivas si es necesario. Por ejemplo, si el proyecto de análisis de datos está experimentando retrasos debido a problemas de calidad de datos, es importante identificar y abordar estos problemas de manera oportuna.
4. **Cierre**: Incluye la conclusión del proyecto, evaluación de resultados y lecciones aprendidas para futuros proyectos. Por ejemplo, al finalizar un proyecto de análisis de datos, se pueden realizar sesiones de retroalimentación con el equipo y los stakeholders para identificar áreas de mejora y oportunidades de aprendizaje.

1.3 Metodologías Ágiles en Data Science

Las metodologías ágiles son enfoques iterativos y colaborativos para el desarrollo de proyectos que priorizan la entrega de valor al cliente y la adaptabilidad al cambio. En el contexto de Data Science, estas metodologías son especialmente útiles debido a la naturaleza exploratoria y cambiante del análisis de datos.

1.3.1 Principios de las Metodologías Ágiles:

1. **Colaboración con el Cliente**: Trabajar en estrecha colaboración con los stakeholders para comprender y satisfacer sus necesidades. Por ejemplo, en un proyecto de análisis de datos para una empresa de telecomunicaciones, el equipo de Data Science puede colaborar con los gerentes de producto para identificar los requisitos y prioridades del negocio.
2. **Entrega Incremental**: Dividir el proyecto en iteraciones o incrementos de trabajo que proporcionen valor tangible de manera temprana. Por ejemplo, en un proyecto de análisis de datos para una empresa de comercio electrónico, cada iteración puede centrarse en un aspecto específico, como la segmentación de clientes o la recomendación de productos.
3. **Flexibilidad y Adaptabilidad**: Estar abierto a cambios en los requisitos y responder de manera rápida y efectiva a nuevas circunstancias. Por ejemplo, si durante el desarrollo de un modelo predictivo se identifican nuevas fuentes de datos relevantes, el equipo de Data Science puede ajustar el enfoque y la estrategia del proyecto en consecuencia.
4. **Enfoque en Personas**: Valorar la comunicación efectiva, la colaboración entre equipos y el empoderamiento de los miembros del equipo. Por ejemplo, al trabajar en un proyecto de análisis de datos, es importante fomentar un ambiente de trabajo colaborativo donde los miembros del equipo se sientan motivados y comprometidos.
5. **Orientación hacia Resultados**: Centrarse en la entrega de resultados concretos y en la satisfacción del cliente. Por ejemplo, en un proyecto de análisis de datos para una empresa de servicios financieros, el éxito del proyecto puede medirse en función de métricas como la precisión del modelo y el impacto en las decisiones comerciales.

1.4 Aplicación de Metodologías Ágiles en Proyectos de Data Science

Aplicar metodologías ágiles en proyectos de Data Science implica adaptar los principios ágiles al ciclo de vida del análisis de datos. Esto implica trabajar de manera iterativa y colaborativa para explorar datos, desarrollar modelos y validar resultados de manera continua.

1.4.1 Ciclo de Vida Ágil en Proyectos de Data Science:

1. **Planificación Iterativa**: Definir objetivos claros para cada iteración o sprint, identificando las tareas necesarias para lograr esos objetivos. Por ejemplo, en un proyecto de análisis de datos para una empresa de seguros, cada iteración puede enfocarse en una parte específica del proceso de modelado, como la selección de variables o la evaluación de modelos.
2. **Desarrollo Incremental**: Construir y validar modelos de manera incremental, integrando retroalimentación del cliente y del equipo en cada etapa del proceso. Por ejemplo, en un proyecto de análisis de datos para una empresa de comercio electrónico, el equipo puede desarrollar un modelo de recomendación de productos en varias iteraciones, refinando y mejorando el modelo en cada paso.
3. **Evaluación Continua**: Evaluar y validar resultados de manera continua, midiendo el desempeño de los modelos y ajustando la estrategia según sea necesario. Por ejemplo, en un

proyecto de análisis de datos para una empresa de telecomunicaciones, el equipo puede monitorear métricas como la precisión y el recall del modelo de detección de fraude y realizar ajustes en función de los resultados.

4. **Adaptación y Mejora**: Estar abierto a cambios en los requisitos y responder de manera rápida y efectiva a nuevas circunstancias. Por ejemplo, si durante el desarrollo de un modelo de clasificación de clientes se identifican nuevas variables predictoras relevantes, el equipo puede ajustar el enfoque del proyecto y volver a entrenar el modelo en consecuencia.

1.5 Herramientas y Tecnologías para Proyectos de Data Science

En proyectos de Data Science, el uso de herramientas y tecnologías adecuadas puede facilitar el desarrollo, la colaboración y la implementación de soluciones analíticas. Algunas herramientas y tecnologías comunes incluyen:

1. **Python**: Un lenguaje de programación popular en el análisis de datos debido a su amplia variedad de bibliotecas y su sintaxis intuitiva. Por ejemplo, pandas es una biblioteca de Python ampliamente utilizada para la manipulación y análisis de datos tabulares.
2. **Jupyter Notebooks**: Un entorno interactivo para escribir y ejecutar código, visualizar datos y compartir resultados. Por ejemplo, en un proyecto de análisis de datos, los Jupyter Notebooks pueden utilizarse para explorar datos, desarrollar modelos y presentar resultados de manera interactiva.
3. **Git y GitHub**: Herramientas de control de versiones que facilitan la colaboración y el seguimiento de cambios en el código y los archivos de un proyecto. Por ejemplo, en un proyecto de análisis de datos, Git y GitHub pueden utilizarse para gestionar el código fuente y los conjuntos de datos, permitiendo a los miembros del equipo colaborar de manera eficiente.
4. **Bibliotecas de Machine Learning**: Conjuntos de herramientas y algoritmos para desarrollar modelos predictivos y analíticos. Scikit-Learn y TensorFlow son bibliotecas populares en el análisis de datos debido a su facilidad de uso y rendimiento.
5. **Docker**: Para la creación de entornos de desarrollo reproducibles y escalables, garantizando la consistencia y la portabilidad de los proyectos. Docker simplifica la gestión de entornos de desarrollo y facilita la colaboración entre equipos.

La gestión de proyectos y las metodologías ágiles son fundamentales para el éxito de proyectos de Data Science. Al aplicar estos principios y herramientas, los equipos pueden mejorar la eficiencia, la calidad y la satisfacción del cliente en sus proyectos de análisis de datos.

2 Análisis de Calidad de Datos

El análisis de la calidad de datos es una parte fundamental en el proceso de ciencias de datos. Su objetivo es evaluar la integridad, precisión, consistencia y confiabilidad de los datos utilizados en un proyecto o análisis

1. **Identificación de valores faltantes:** Este paso implica detectar si hay campos o variables en el conjunto de datos que carecen de valores. Los valores faltantes pueden deberse a diversos motivos, como errores en la entrada de datos, fallas en los sistemas de recolección o simplemente la ausencia de información.

2. **Detección de inconsistencias en los datos:** Consiste en buscar discrepancias o contradicciones entre los datos. Por ejemplo, si en un conjunto de datos sobre ventas se encuentra que

el número de productos vendidos en un día es mayor que el inventario inicial, esto podría ser una inconsistencia.

3. **Identificación de posibles errores:** Esto implica buscar valores atípicos, anomalías o datos que no tienen sentido dentro del contexto del conjunto de datos. Los errores pueden manifestarse de diversas formas, como valores extremadamente altos o bajos que no son representativos del resto de los datos, o datos que violan las restricciones lógicas de un dominio específico.
4. **Evaluación de la consistencia y precisión:** Se refiere a verificar si los datos están en concordancia con las expectativas y reglas del dominio del problema. Esto implica comprobar la coherencia de los datos con respecto a las reglas de negocio y los estándares establecidos.
5. **Limpieza de datos:** Una vez identificados los problemas de calidad de los datos, se procede a corregirlos o eliminarlos. Esto puede implicar imputar valores faltantes, corregir errores evidentes o eliminar registros que no cumplen con ciertos criterios de calidad.

2.0.1 llenar valores faltantes

Para llenar valores faltantes en conjuntos de datos tanto cuantitativos como cualitativos, existen varias estrategias comunes que los científicos de datos suelen emplear:

- **Valores cuantitativos:**
    1. **Imputación por la media o mediana:** Los valores faltantes se reemplazan por la media o mediana de la variable en cuestión. Esta estrategia es simple y efectiva cuando los datos siguen una distribución normal y los valores faltantes son aleatorios.
    2. **Imputación por regresión:** Se utiliza un modelo de regresión para predecir los valores faltantes en función de otras variables del conjunto de datos. Esta técnica es útil cuando existe una correlación significativa entre la variable con valores faltantes y otras variables del conjunto de datos.
    3. **Métodos basados en vecinos más cercanos (KNN):** Los valores faltantes se imputan utilizando los valores de las observaciones más similares en función de una métrica de distancia. Esta estrategia es útil cuando las observaciones se pueden agrupar en un espacio métrico.
    4. **Imputación múltiple:** Se generan múltiples imputaciones para los valores faltantes, teniendo en cuenta la incertidumbre asociada con la imputación. Esta técnica es útil cuando se desea tener en cuenta la variabilidad en los datos imputados.
- **Valores cualitativos:**
    1. **Moda o valor más frecuente:** Los valores faltantes se reemplazan por el valor más común o moda de la variable categórica. Esta estrategia es simple y efectiva cuando hay una categoría dominante en la variable.
    2. **Imputación por regresión logística:** Se utiliza un modelo de regresión logística para predecir la categoría de los valores faltantes en función de otras variables del conjunto de datos.
    3. **Muestreo de valores:** Los valores faltantes se imputan seleccionando aleatoriamente valores observados de la misma variable categórica.

4. **Imputación basada en modelos de clasificación:** Se utilizan modelos de clasificación (como árboles de decisión o métodos de clasificación más avanzados) para predecir la categoría de los valores faltantes en función de otras variables predictoras.

3 Consolidando Insights Accionables

¡Bienvenidos a la sesión final dedicada a consolidar los hallazgos del análisis en insights accionables! En esta etapa crucial, nos sumergiremos en el vasto mar de datos para extraer sabiduría que guiará nuestras decisiones en Ironhack. Durante esta presentación detallada, exploraremos los aspectos fundamentales del análisis de datos, desde su exploración inicial hasta la presentación final de insights. Nuestro objetivo es proporcionarles las herramientas y el conocimiento necesarios para convertir datos crudos en información valiosa y accionable.

3.1 ¿Qué es un Insight Accionable?

Un insight accionable va más allá de la simple observación; es una revelación que no solo ilumina, sino que también impulsa a la acción. Estos insights son puntos de inflexión que desencadenan decisiones informadas y estratégicas. Por ejemplo, descubrir que los estudiantes que participan en actividades extracurriculares tienen un rendimiento académico más alto puede conducir a la implementación de más actividades fuera del aula.

3.1.1 Ejemplo:

Imaginemos que, después de analizar los datos de rendimiento académico de una escuela, descubrimos que los estudiantes que participan en actividades extracurriculares tienen un promedio de calificaciones significativamente más alto que aquellos que no participan. Este insight sugiere una estrategia clara para mejorar el rendimiento académico implementando más actividades extracurriculares.

3.1.2 Componentes de un Insight Accionable:

1. **Relevancia**: Debe estar directamente relacionado con los objetivos y necesidades de la organización. Identificar insights relevantes garantiza que las acciones derivadas tengan un impacto significativo en los resultados deseados.
2. **Claridad**: Debe ser fácilmente comprensible y comunicable. La claridad en la presentación de insights facilita su comprensión por parte de todas las partes interesadas, lo que aumenta la probabilidad de adopción de medidas.
3. **Acción**: Debe sugerir una acción específica o una decisión a tomar. Los insights deben ser lo suficientemente claros como para inspirar acciones concretas que impulsen el cambio positivo.

3.2 Resumen del Análisis Exploratorio de Datos (AED)

El análisis exploratorio de datos (AED) es la brújula que nos guía a través del vasto territorio de nuestros conjuntos de datos. Nos sumerge en la riqueza de la información, revelando patrones, tendencias y anomalías que pueden pasar desapercibidas a simple vista. Desde la distribución de calificaciones hasta la correlación entre variables, el AED nos proporciona una comprensión profunda de nuestros datos y nos ayuda a formular hipótesis valiosas para análisis posteriores.

3.2.1 Ejemplo de AED:

Al realizar un AED en los datos de los estudiantes de Ironhack, podemos utilizar técnicas como histogramas, diagramas de dispersión y matrices de correlación para visualizar la distribución de calificaciones, explorar relaciones entre variables como horas de estudio y rendimiento académico, y detectar posibles valores atípicos que requieran una mayor investigación.

3.2.2 Componentes del AED:

1. **Exploración de Datos Univariable**: Análisis de una variable a la vez para comprender su distribución y estadísticas descriptivas. Este enfoque nos permite entender la naturaleza de cada variable y cómo se distribuyen en el conjunto de datos.
2. **Exploración de Datos Bivariable**: Análisis de la relación entre dos variables para identificar posibles asociaciones o correlaciones. Este análisis nos ayuda a comprender las interacciones entre diferentes variables y su impacto en los resultados.
3. **Identificación de Valores Atípicos**: Detección de puntos que se desvían significativamente de la tendencia general de los datos. La identificación de valores atípicos nos permite comprender mejor la distribución de los datos y evaluar su influencia en nuestros análisis.

3.3 Insights de Calidad de Datos

La calidad de los datos es la piedra angular de cualquier análisis significativo. Los datos incompletos, incorrectos o inconsistentes pueden socavar la validez de nuestros resultados y conducir a conclusiones erróneas. Por lo tanto, es crucial realizar una evaluación rigurosa de la calidad de los datos y tomar medidas para abordar cualquier problema identificado.

3.3.1 Ejemplo de Problemas de Calidad de Datos:

Supongamos que al analizar los datos de asistencia de los estudiantes de Ironhack, descubrimos que hay entradas duplicadas debido a errores en el proceso de registro. Esto podría distorsionar nuestros análisis y llevar a conclusiones incorrectas sobre la asistencia real de los estudiantes. Para abordar este problema, necesitaríamos implementar un proceso de limpieza de datos para identificar y eliminar duplicados de manera sistemática.

3.3.2 Estrategias de Mejora de Calidad de Datos:

1. **Limpieza de Datos**: Identificación y corrección de errores, valores atípicos y datos faltantes. La limpieza de datos es un proceso esencial para garantizar la integridad y la precisión de nuestros análisis.
2. **Validación de Datos**: Verificación de la precisión y consistencia de los datos mediante técnicas como la validación cruzada. La validación de datos nos ayuda a confirmar la calidad de nuestros datos y a identificar posibles problemas.
3. **Actualización Regular**: Mantenimiento constante de la integridad de los datos mediante actualizaciones periódicas y revisión continua. La actualización regular de los datos garantiza que estén actualizados y reflejen con precisión la realidad en curso.

3.4 Resultados del Análisis de Cohortes

El análisis de cohortes es una herramienta poderosa para comprender cómo se comportan grupos de individuos a lo largo del tiempo. Al dividir a los usuarios en cohortes basadas en ciertos criterios (por ejemplo, fecha de inscripción), podemos rastrear su comportamiento y evaluar el impacto de diferentes factores en su experiencia.

3.4.1 Ejemplo de Análisis de Cohortes:

Supongamos que al analizar las tasas de retención de los estudiantes de Ironhack en función de la cohorte de ingreso, descubrimos que las cohortes que se inscribieron durante ciertos períodos tienen una tasa de retención más alta que otras. Este insight nos permite identificar tendencias y patrones significativos en la experiencia del estudiante y nos brinda información valiosa para mejorar nuestras estrategias de retención.

3.4.2 Beneficios del Análisis de Cohortes:

1. **Identificación de Tendencias a Largo Plazo**: Permite observar cómo cambian los comportamientos a lo largo del tiempo. El análisis de cohortes nos proporciona una visión a largo plazo de la evolución del comportamiento de los usuarios.
2. **Comparación entre Grupos Homogéneos**: Facilita la comparación de diferentes cohortes con características similares. Esto nos ayuda a comprender mejor las diferencias en el comportamiento de los usuarios y a identificar áreas de mejora.
3. **Evaluación del Impacto de Intervenciones**: Ayuda a evaluar el efecto de cambios o intervenciones en la experiencia del usuario. El análisis de cohortes nos permite medir el impacto de nuestras acciones y ajustar nuestras estrategias en consecuencia.

3.5 Creando una Presentación Efectiva

Una presentación efectiva es el vehículo que lleva nuestros insights desde el laboratorio de datos hasta la sala de juntas, donde pueden inspirar acción y cambio. Para lograr esto, es crucial diseñar una narrativa coherente y visualmente atractiva que resalte los puntos clave y motive a la audiencia a tomar medidas.

3.5.1 Componentes de una Presentación Efectiva:

1. **Introducción Impactante**: Captura la atención de la audiencia y establece el contexto para el resto de la presentación. Una introducción impactante establece el tono y despierta el interés de la audiencia desde el principio.
2. **Visualizaciones Claras y Concisas**: Utiliza gráficos y tablas para ilustrar tus puntos de manera efectiva y comprensible. Las visualizaciones claras y concisas ayudan a transmitir información de manera efectiva y atractiva.
3. **Narrativa Coherente**: Estructura tu presentación de manera lógica y secuencial para mantener el interés y la claridad. Una narrativa coherente guía a la audiencia a través de la presentación de manera clara y comprensible.

4. **Llamado a la Acción**: Concluye tu presentación con recomendaciones claras y acciones específicas que se deriven de tus insights. Un llamado a la acción motivador inspira a la audiencia a tomar medidas basadas en los insights presentados.

3.6 El Arte de Contar Historias con Datos

Contar historias con datos es el arte de transformar números en narrativas convincentes que resuenen con la audiencia. Al agregar un toque humano a nuestros análisis, podemos capturar la atención y el interés de la audiencia, inspirando empatía y acción.

3.6.1 Estrategias para Contar Historias con Datos:

1. **Identifica tu Audiencia**: Comprende quiénes son tus espectadores y adapta tu narrativa para resonar con ellos. Al conocer a tu audiencia, puedes personalizar tu mensaje para que sea relevante y persuasivo.
2. **Personaliza tus Ejemplos**: Utiliza ejemplos y casos de estudio relevantes y emocionalmente impactantes. Los ejemplos personalizados ayudan a contextualizar los datos y a hacer que la información sea más accesible y significativa.
3. **Construye una Narrativa Emocional**: Combina datos con anécdotas humanas para crear una conexión emocional con tu audiencia. Una narrativa emocional involucra a la audiencia a un nivel personal, lo que aumenta la resonancia y el impacto del mensaje.
4. **Utiliza Visualizaciones Persuasivas**: Incorpora gráficos y visualizaciones que refuercen tu mensaje y lo hagan memorable. Las visualizaciones persuasivas son herramientas poderosas para transmitir información de manera impactante y memorable.

3.7 Conclusión

En esta sesión, hemos explorado los fundamentos de consolidar insights accionables, desde la exploración inicial de datos hasta la presentación final de hallazgos. Al integrar estos conceptos en nuestro enfoque de análisis de datos en Ironhack, podemos tomar decisiones más informadas y estratégicas que impulsen el éxito de nuestra organización.

[1]:
```
# Importando la biblioteca pandas para manipulación y análisis de datos
import pandas as pd

# Importando NumPy para operaciones numéricas y manipulación de arreglos
import numpy as np

# Importando Seaborn para visualización de datos estadísticos (opcional, pero␣
↪puede complementar a Plotly)
import seaborn as sns

# Importando Plotly Express para visualizaciones interactivas de alto nivel y␣
↪fáciles de usar
import plotly.express as px

# Importando matplotlib.pyplot para crear gráficos y visualizaciones
```

```
import matplotlib.pyplot as plt

# Importando Plotly Graph Objects para un control más detallado sobre las␣
 ↪visualizaciones
import plotly.graph_objects as go

# Importando itertools para generar combinaciones de columnas
import itertools

# Importando la función seasonal_decompose para la descomposición de series␣
 ↪temporales
from statsmodels.tsa.seasonal import seasonal_decompose
```

[2]:
```
cash_request=pd.read_csv('./project_dataset/extract - cash request - data␣
 ↪analyst.csv')
fees=pd.read_csv('./project_dataset/extract - fees - data analyst - .csv')
```

[3]:
```
plt.figure(figsize=(10, 8))
fig1 = px.imshow(cash_request.isnull(),
                 color_continuous_scale=['black', 'red'],
                 labels=dict(color="NaN"),
                 title="Mapa de calor para cash_request")
fig1.update_layout(width=700, height=700)
fig1.update_coloraxes(showscale=False)
fig1.show()
```

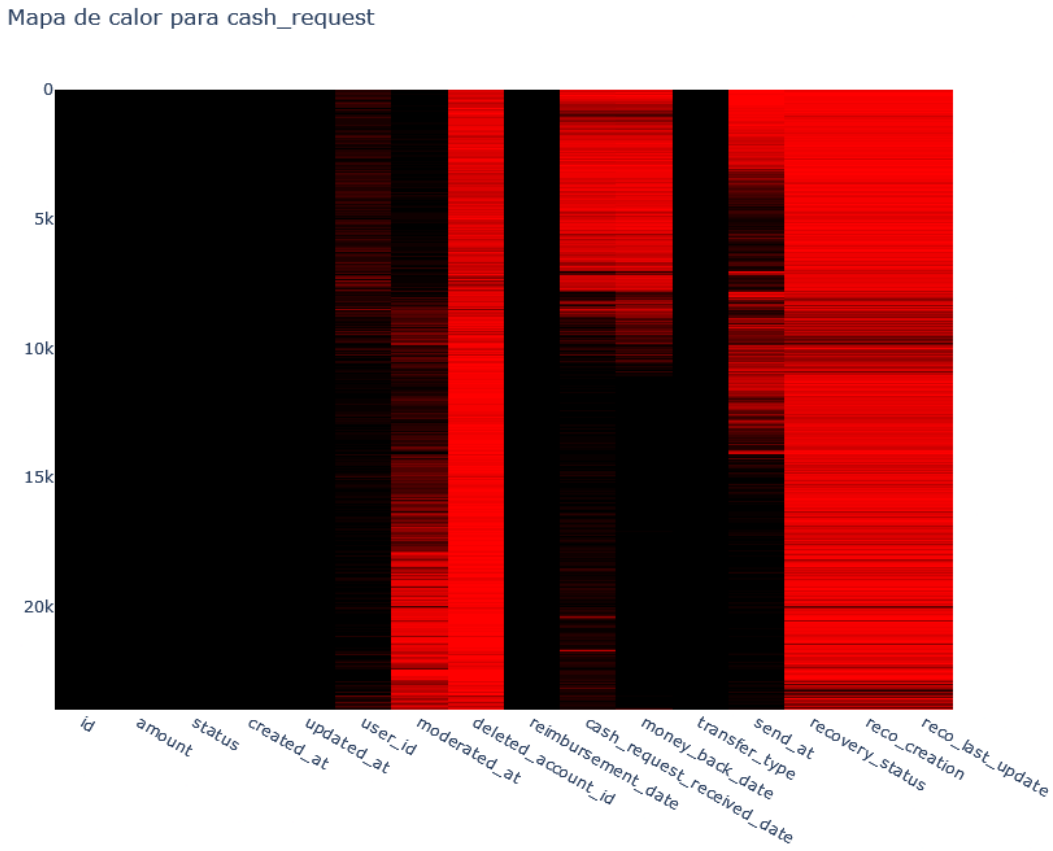


```
<Figure size 1000x800 with 0 Axes>
```

[4]:
```
fig2 = px.imshow(fees.isnull(),
                 color_continuous_scale=['black', 'red'],
                 labels=dict(color="NaN"),
                 title="Mapa de calor para fees")
fig2.update_layout(width=700, height=700)
fig2.update_coloraxes(showscale=False)
fig2.show()
```

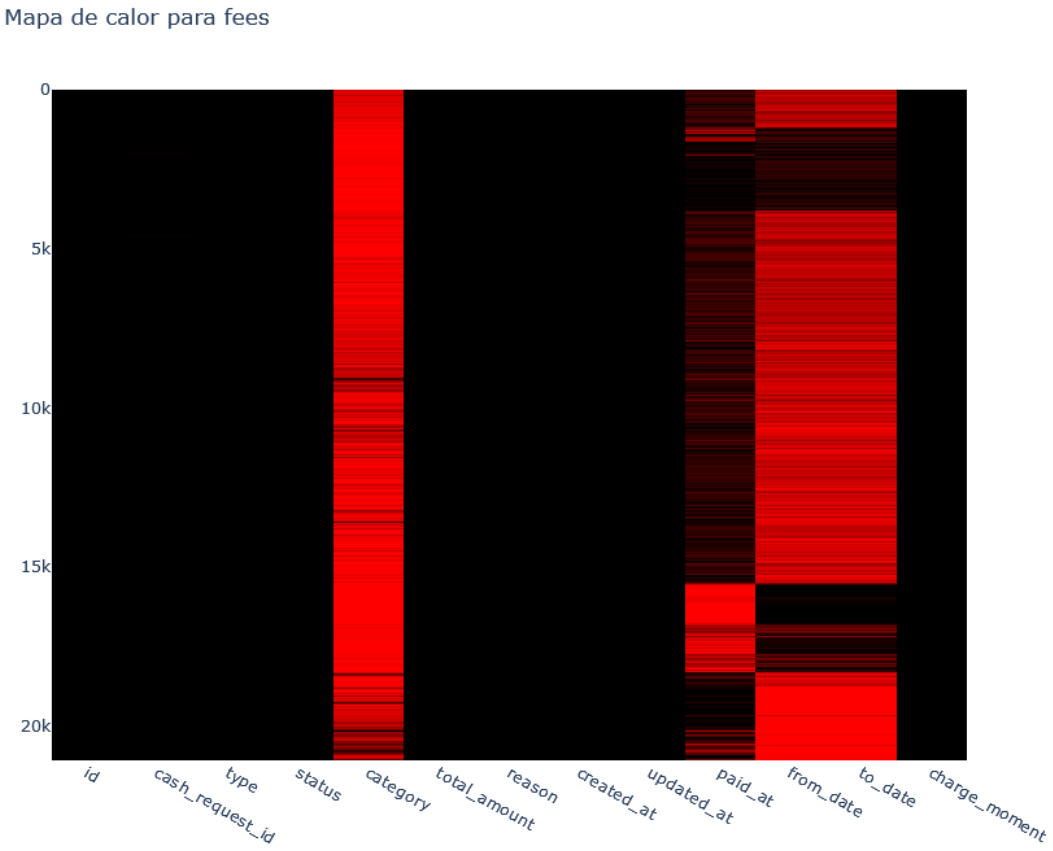

[5]:
```
cash_request.describe()
```

[5]:

	id	amount	user_id	deleted_account_id
count	23970.000000	23970.000000	21867.000000	2104.000000
mean	13910.966124	82.720818	32581.250789	9658.755228
std	7788.117214	26.528065	27618.565773	7972.743249
min	3.000000	1.000000	34.000000	91.000000
25%	7427.250000	50.000000	10804.000000	3767.000000
50%	14270.500000	100.000000	23773.000000	6121.500000
75%	20607.750000	100.000000	46965.000000	16345.000000
max	27010.000000	200.000000	103719.000000	30445.000000

[6]:
```
fees.describe()
```

[6]:

	id	cash_request_id	total_amount
count	21061.000000	21057.000000	21061.000000
mean	10645.355111	16318.449162	5.000237
std	6099.315256	6656.149949	0.034453
min	1.000000	1456.000000	5.000000

```
25%     5385.000000     11745.000000      5.000000
50%    10652.000000     17160.000000      5.000000
75%    15925.000000     21796.000000      5.000000
max    21193.000000     27010.000000     10.000000
```

[7]:
```
cash_request.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 23970 entries, 0 to 23969
Data columns (total 16 columns):
 #   Column                      Non-Null Count  Dtype
---  ------                      --------------  -----
 0   id                          23970 non-null  int64
 1   amount                      23970 non-null  float64
 2   status                      23970 non-null  object
 3   created_at                  23970 non-null  object
 4   updated_at                  23970 non-null  object
 5   user_id                     21867 non-null  float64
 6   moderated_at                16035 non-null  object
 7   deleted_account_id          2104 non-null   float64
 8   reimbursement_date          23970 non-null  object
 9   cash_request_received_date  16289 non-null  object
 10  money_back_date             16543 non-null  object
 11  transfer_type               23970 non-null  object
 12  send_at                     16641 non-null  object
 13  recovery_status             3330 non-null   object
 14  reco_creation               3330 non-null   object
 15  reco_last_update            3330 non-null   object
dtypes: float64(3), int64(1), object(12)
memory usage: 2.9+ MB
```

[8]:
```
fees.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21061 entries, 0 to 21060
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   id               21061 non-null  int64
 1   cash_request_id  21057 non-null  float64
 2   type             21061 non-null  object
 3   status           21061 non-null  object
 4   category         2196 non-null   object
 5   total_amount     21061 non-null  float64
 6   reason           21061 non-null  object
 7   created_at       21061 non-null  object
 8   updated_at       21061 non-null  object
 9   paid_at          15531 non-null  object
```

```
 10  from_date        7766 non-null   object
 11  to_date          7766 non-null   object
 12  charge_moment    21061 non-null  object
dtypes: float64(2), int64(1), object(10)
memory usage: 2.1+ MB
```

4 Revisión de columnas con valores clave

[9]:
```
columnas_cash_request=cash_request.columns.tolist()
for i in columnas_cash_request:
    print("============================")
    print(f"{cash_request[i].value_counts().head(10)}")
```

```
============================
id
5        1
15322    1
19569    1
15338    1
15329    1
15341    1
15336    1
15334    1
15165    1
15346    1
Name: count, dtype: int64
============================
amount
100.0    16094
50.0      5304
25.0      1276
80.0       267
60.0       190
70.0       151
20.0       132
30.0       114
40.0       100
90.0        91
Name: count, dtype: int64
============================
status
money_back               16397
rejected                  6568
direct_debit_rejected      831
active                      59
transaction_declined        48
direct_debit_sent           34
```

```
canceled                    33
Name: count, dtype: int64
==========================
created_at
2019-12-10 19:05:21.596873+00    1
2020-09-09 11:06:31.382449+00    1
2020-10-07 05:56:54.442506+00    1
2020-09-09 12:32:29.661278+00    1
2020-09-09 11:42:31.956338+00    1
2020-09-09 12:43:05.909299+00    1
2020-09-09 12:23:09.95394+00     1
2020-09-09 12:16:17.993242+00    1
2020-09-08 16:01:25.146577+00    1
2020-09-09 12:57:42.599222+00    1
Name: count, dtype: int64
==========================
updated_at
2019-12-11 16:47:42.40783+00     1
2020-12-18 13:10:44.348964+00    1
2020-12-18 13:10:44.448561+00    1
2020-12-18 13:10:44.439598+00    1
2020-12-18 13:10:44.429451+00    1
2020-12-18 13:10:44.420825+00    1
2020-12-18 13:10:44.408793+00    1
2020-12-18 13:10:44.396931+00    1
2020-12-18 13:10:44.380111+00    1
2020-12-18 13:10:44.368343+00    1
Name: count, dtype: int64
==========================
user_id
3377.0     19
2142.0     18
13851.0    18
2530.0     17
1159.0     17
10086.0    17
15219.0    17
6634.0     16
9901.0     16
20583.0    16
Name: count, dtype: int64
==========================
moderated_at
2019-12-11 16:47:42.405646+00    1
2020-07-10 12:43:27.336286+00    1
2020-07-08 17:55:11.030979+00    1
2020-07-02 12:53:57.219204+00    1
2020-07-17 09:13:58.632576+00    1
```

```
2020-07-22 08:58:35.732462+00    1
2020-07-11 12:21:17.278948+00    1
2020-07-20 13:16:58.240135+00    1
2020-08-06 08:51:36.743714+00    1
2020-07-24 08:37:06.064422+00    1
Name: count, dtype: int64
==========================
deleted_account_id
6334.0     19
3767.0     16
11444.0    16
4047.0     15
24168.0    13
23326.0    10
4203.0      9
7180.0      9
4267.0      9
12175.0     9
Name: count, dtype: int64
==========================
reimbursement_date
2020-11-05 22:00:00+00    1106
2020-10-05 22:00:00+00     761
2020-08-05 22:00:00+00     732
2020-09-07 22:00:00+00     554
2020-11-02 22:00:00+00     432
2020-11-04 22:00:00+00     359
2020-11-03 22:00:00+00     350
2020-08-04 22:00:00+00     350
2020-11-09 22:00:00+00     333
2020-09-04 22:00:00+00     324
Name: count, dtype: int64
==========================
cash_request_received_date
2020-10-27    716
2020-10-28    482
2020-10-30    435
2020-10-20    355
2020-11-03    345
2020-10-24    309
2020-10-13    271
2020-10-21    265
2020-09-08    258
2020-10-22    255
Name: count, dtype: int64
==========================
money_back_date
2020-08-04 22:00:00+00    364
```

```
2020-08-05 22:00:00+00    295
2020-07-29 22:00:00+00    244
2020-07-07 22:00:00+00    180
2020-09-01 22:00:00+00    134
2020-11-03 23:00:00+00    130
2020-10-06 22:00:00+00    125
2020-09-02 22:00:00+00    118
2020-08-30 22:00:00+00    110
2020-11-11 23:00:00+00    102
Name: count, dtype: int64
============================
transfer_type
instant    13882
regular    10088
Name: count, dtype: int64
============================
send_at
2020-10-23 15:21:26.878525+00    1
2020-10-15 09:12:29.887167+00    1
2020-10-15 09:26:23.065397+00    1
2020-10-08 08:51:51.386371+00    1
2020-10-08 07:52:04.638453+00    1
2020-11-01 10:40:30.955915+00    1
2020-10-08 08:53:46.065496+00    1
2020-10-08 09:21:43.067327+00    1
2020-10-08 07:14:09.553728+00    1
2020-10-08 09:42:20.888932+00    1
Name: count, dtype: int64
============================
recovery_status
completed               2468
pending                  845
pending_direct_debit      16
cancelled                  1
Name: count, dtype: int64
============================
reco_creation
2020-06-12 22:27:04.837525+00    1
2020-11-11 23:01:30.183037+00    1
2020-09-22 22:34:09.112102+00    1
2020-09-22 22:23:31.824006+00    1
2020-09-22 22:41:35.956212+00    1
2020-10-02 22:18:26.544227+00    1
2020-09-11 22:43:31.480966+00    1
2020-09-22 22:26:39.034945+00    1
2020-10-04 22:31:44.850342+00    1
2020-10-03 22:28:33.169866+00    1
Name: count, dtype: int64
```

```
==========
reco_last_update
2020-07-06 03:36:03.030904+00    1
2020-11-11 23:01:33.548034+00    1
2020-10-03 04:45:39.909619+00    1
2020-09-22 22:23:35.480525+00    1
2020-10-03 07:48:36.457294+00    1
2020-11-06 01:01:41.491634+00    1
2020-10-05 15:03:26.030634+00    1
2020-09-24 15:40:09.086746+00    1
2020-10-15 02:56:51.541306+00    1
2020-10-05 05:46:13.88533+00     1
Name: count, dtype: int64
```

[10]:
```
columnas_fees=fees.columns.tolist()
for i in columnas_fees:
    print("==========")
    print(f"{fees[i].value_counts().head(10)}")
```

```
==========
id
6537    1
7852    1
7846    1
7844    1
6968    1
7819    1
7816    1
7815    1
9183    1
7814    1
Name: count, dtype: int64
==========
cash_request_id
12225.0    35
5006.0     28
4410.0     24
12452.0    23
11376.0    21
2358.0     19
11746.0    17
15319.0    16
4956.0     15
8713.0     15
Name: count, dtype: int64
==========
type
instant_payment    11099
```

```
postpone            7766
incident            2196
Name: count, dtype: int64
==========================
status
accepted     14841
cancelled     4938
rejected      1194
confirmed       88
Name: count, dtype: int64
==========================
category
rejected_direct_debit     1599
month_delay_on_payment     597
Name: count, dtype: int64
==========================
total_amount
5.0     21060
10.0        1
Name: count, dtype: int64
==========================
reason
rejected direct debit               1599
month delay on payment - 9/2020      283
month delay on payment - 8/2020      203
month delay on payment - 10/2020     102
Postpone Cash Request 12225           34
Postpone Cash Request 5006            25
Postpone Cash Request 4410            23
Postpone Cash Request 12452           20
Postpone Cash Request 11376           20
Postpone Cash Request 2358            18
Name: count, dtype: int64
==========================
created_at
2020-06-20 22:12:27.824285+00    13
2020-06-10 07:49:37.83168+00      4
2020-06-19 16:57:53.686817+00     3
2020-06-23 07:46:15.133376+00     3
2020-06-20 08:20:50.052537+00     2
2020-06-16 20:49:46.374314+00     2
2020-09-22 10:14:11.331781+00     2
2020-06-23 04:07:13.711326+00     2
2020-06-20 04:50:05.304195+00     2
2020-06-23 00:21:05.11354+00      2
Name: count, dtype: int64
==========================
updated_at
```

```
2020-10-13 14:25:09.396112+00    1
2020-10-13 14:25:11.713775+00    1
2020-10-13 14:25:11.710272+00    1
2020-10-13 14:25:11.706004+00    1
2020-10-13 14:25:11.703705+00    1
2020-10-13 14:25:11.698162+00    1
2020-10-13 14:25:11.694476+00    1
2020-10-13 14:25:11.692227+00    1
2020-10-13 14:25:11.689347+00    1
2020-10-13 14:25:11.687989+00    1
Name: count, dtype: int64
==========================
paid_at
2020-12-07 16:53:12+00           2
2020-11-05 13:31:25+00           2
2020-12-17 14:50:07.47011+00     1
2020-11-16 19:53:57.573859+00    1
2020-11-06 04:27:32.171688+00    1
2020-11-03 07:04:29.547314+00    1
2020-10-08 07:04:02.101196+00    1
2020-11-07 19:54:47.641021+00    1
2020-10-08 07:04:32.541581+00    1
2020-10-06 19:32:44.115792+00    1
Name: count, dtype: int64
==========================
from_date
2020-10-05 22:00:00+00    297
2020-11-05 22:00:00+00    281
2020-09-04 22:00:00+00    241
2020-08-05 22:00:00+00    241
2020-09-07 22:00:00+00    207
2020-11-02 22:00:00+00    192
2020-11-04 22:00:00+00    137
2020-10-06 22:00:00+00    127
2020-08-04 22:00:00+00    120
2020-10-26 22:00:00+00    104
Name: count, dtype: int64
==========================
to_date
2020-11-06 11:00:00+00    192
2020-11-05 11:00:00+00    187
2020-10-30 23:00:00+00    150
2020-10-04 22:00:00+00    148
2020-09-04 22:00:00+00    124
2020-10-31 11:00:00+00    111
2020-11-04 23:00:00+00    103
2020-11-04 22:00:00+00     93
2020-12-05 11:00:00+00     89
```

```
2020-10-07 22:00:00+00     83
Name: count, dtype: int64
============================
charge_moment
after     16724
before     4337
Name: count, dtype: int64
```

5 Visualización de distribuciones de datos

[11]:
```
columnas_numericas_cash_request=cash_request.describe().columns.tolist()
for c in columnas_numericas_cash_request:
    fig = px.histogram(cash_request, x=c, title=f'Histograma de {c}')
    fig.update_layout(height=500)
    fig.show()
```

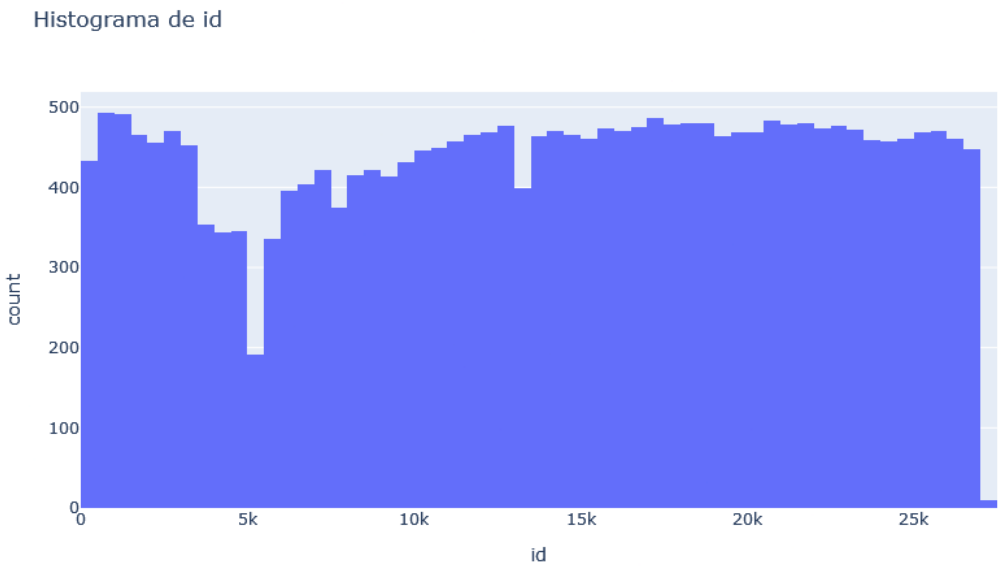

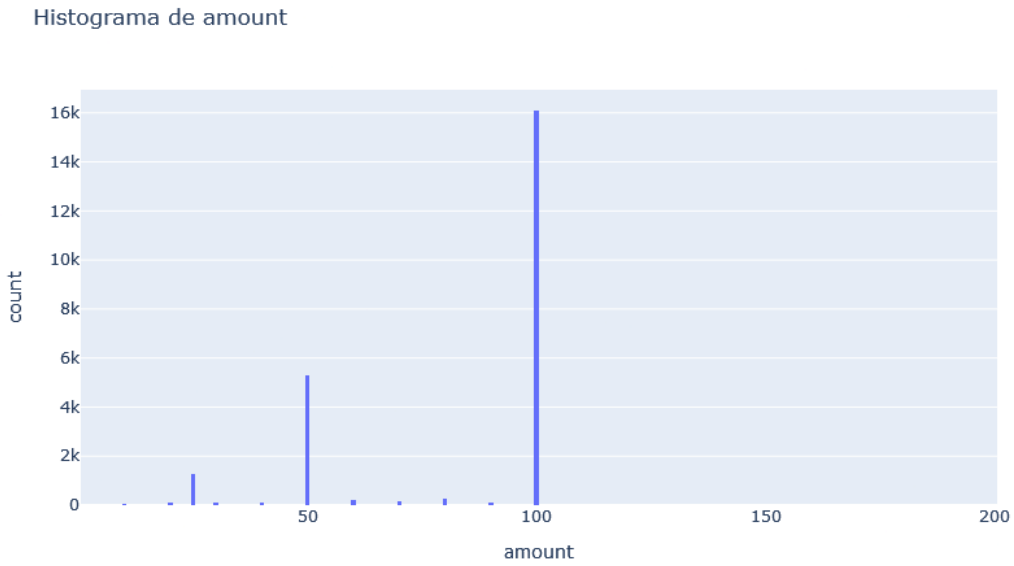
Histograma de amount
16k
14k
12k
10k
8k
6k
4k
2k
0
count
50
100
150
200
amount

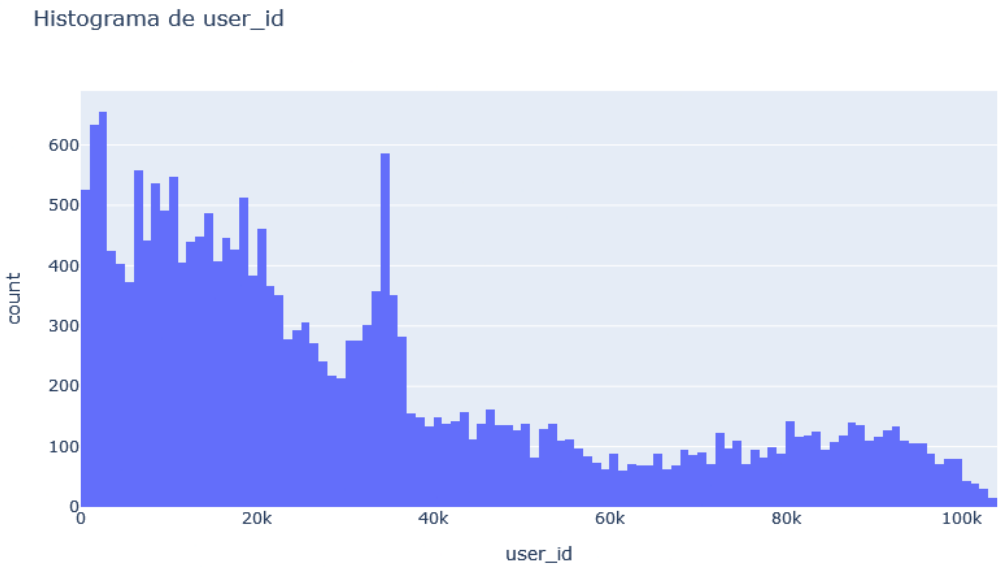
Histograma de user_id
600
500
400
300
200
100
0
count
0
20k
40k
60k
80k
100k
user_id

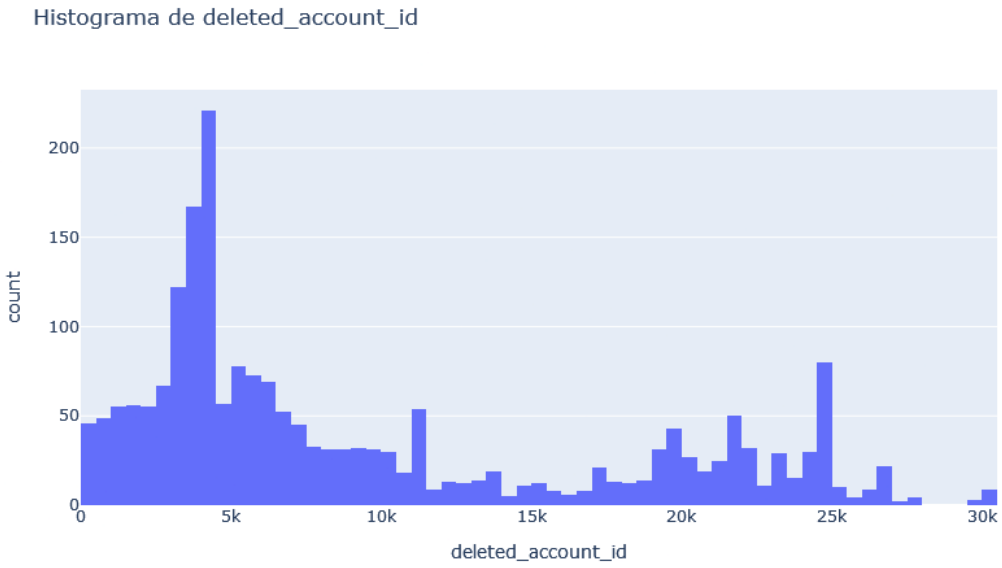

[12]:
```
columnas_numericas_fees=fees.describe().columns.tolist()
for c in columnas_numericas_fees:
    fig = px.histogram(fees, x=c, title=f'Histograma de {c}')
    fig.update_layout(height=500)
    fig.show()
```

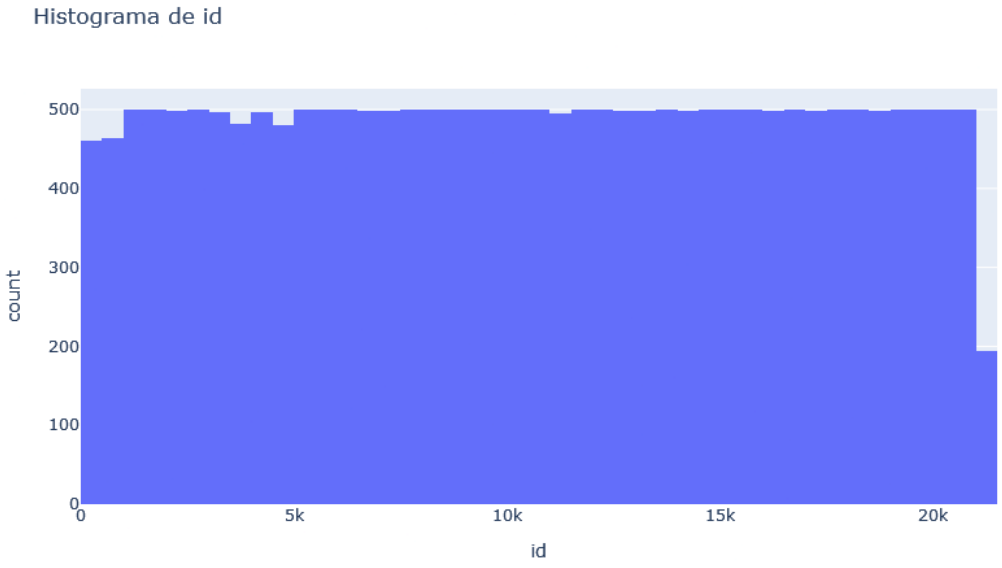

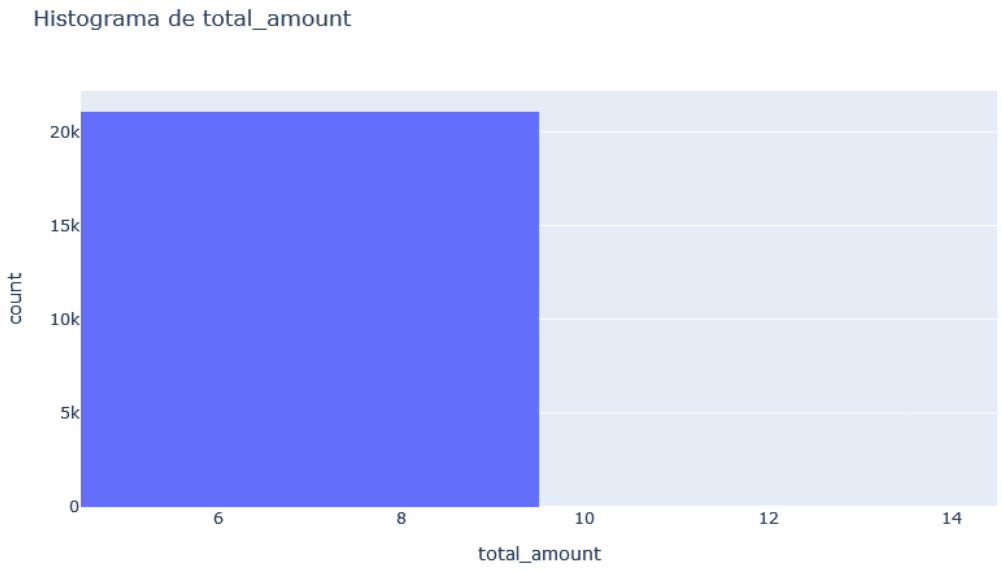

[13]:
```
for c in columnas_cash_request:
    if c not in columnas_numericas_cash_request:
        counts = cash_request[c].value_counts()
        if len(counts)<=10:
```

```
            fig = px.pie(names=counts.index, values=counts.values,␣
↪title=f'Distribución de {c}')
            fig.update_layout(height=500)
            fig.show()
```

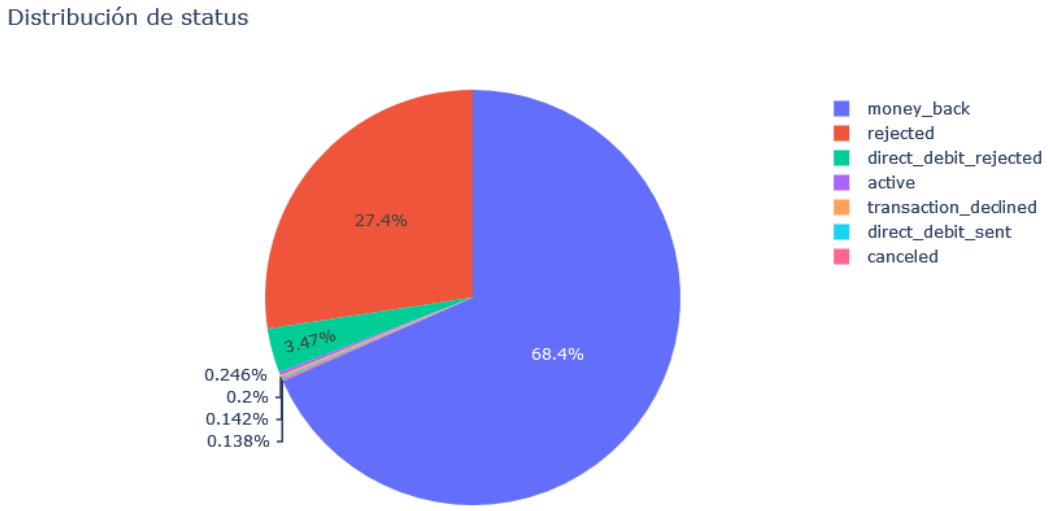

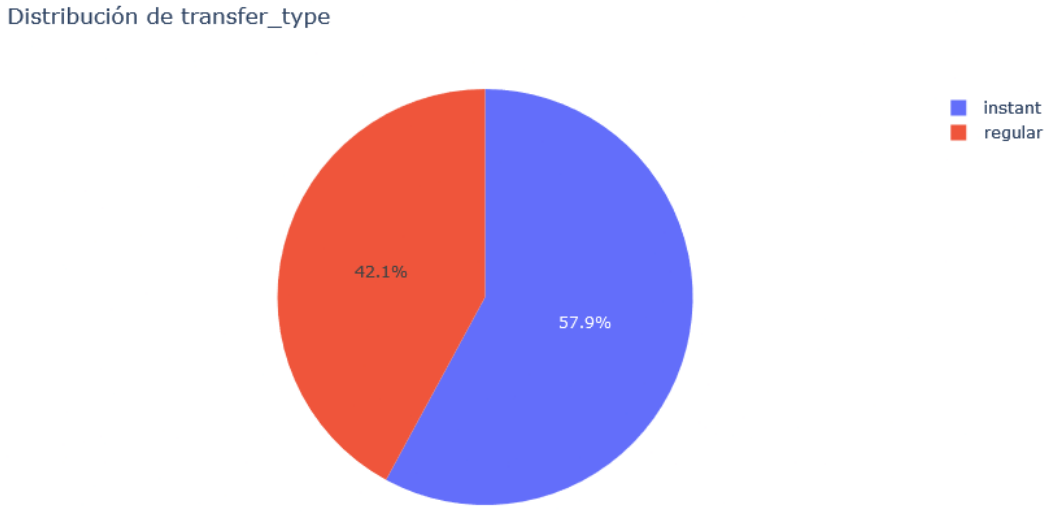

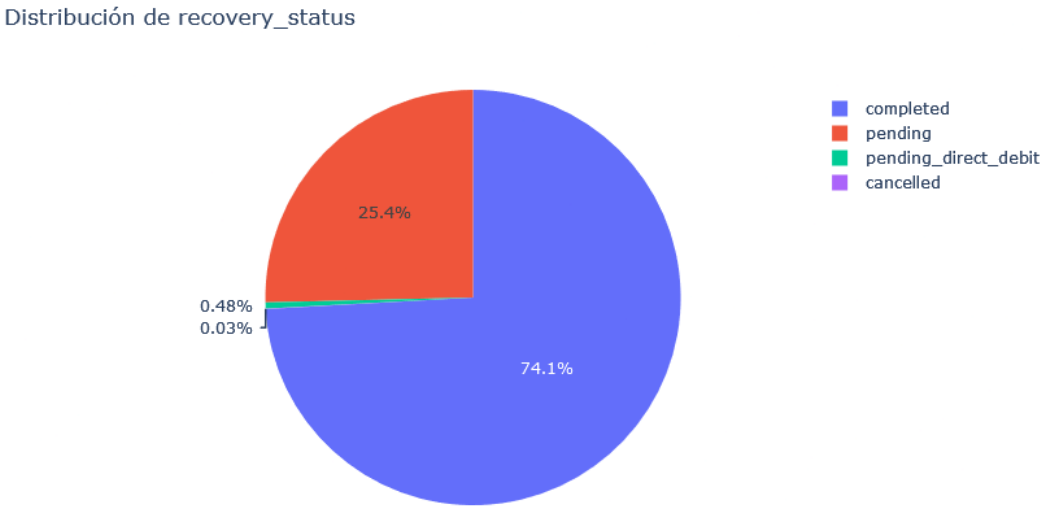

[14]:
```
for c in columnas_fees:
    if c not in columnas_numericas_fees:
        counts = fees[c].value_counts()
        if len(counts)<=10:
            fig = px.pie(names=counts.index, values=counts.values,␣
 ↪title=f'Distribución de {c}')
            fig.update_layout(height=500)
            fig.show()
```

Distribución de type

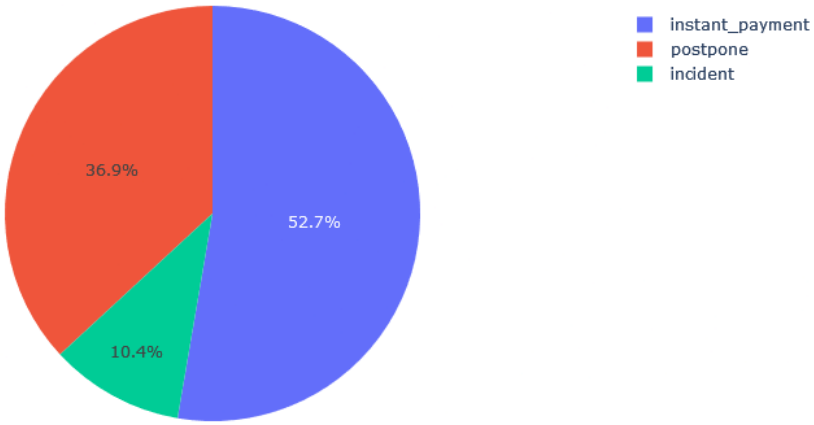

Distribución de status

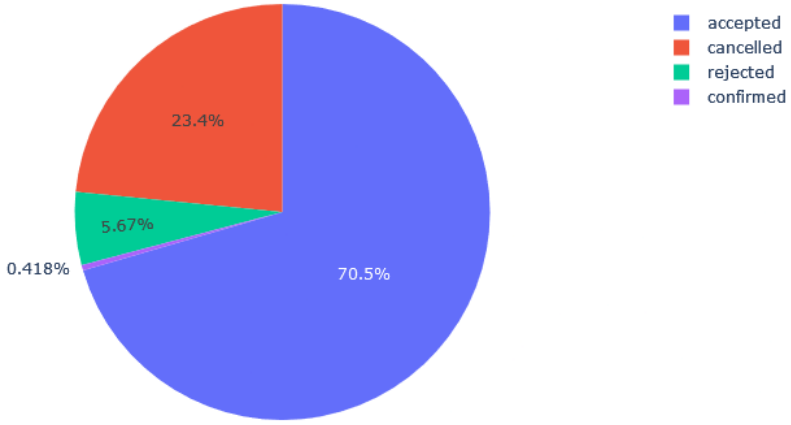

Distribución de category

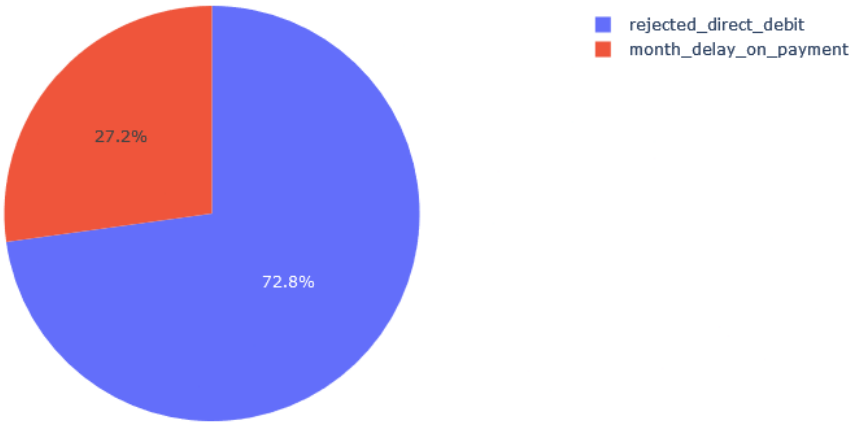

Distribución de charge_moment

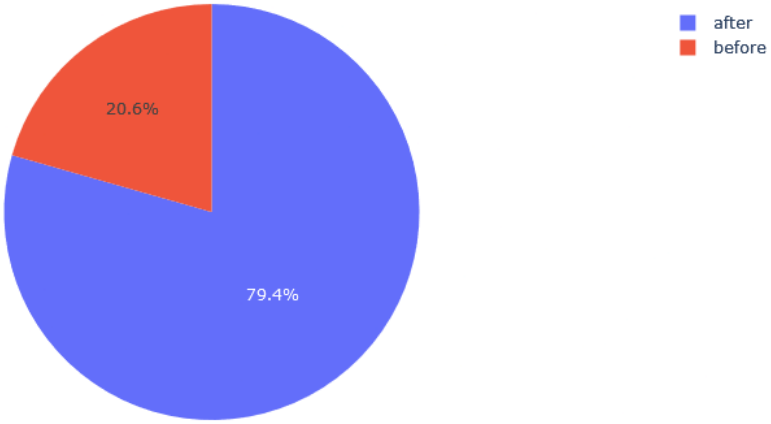

6 Identificación de valores atípicos

[15]:
```
for c in columnas_numericas_cash_request:
    fig = px.box(cash_request, y=c, title=f'Boxplot de {c}')
    fig.update_layout(height=500)
    fig.show()
```

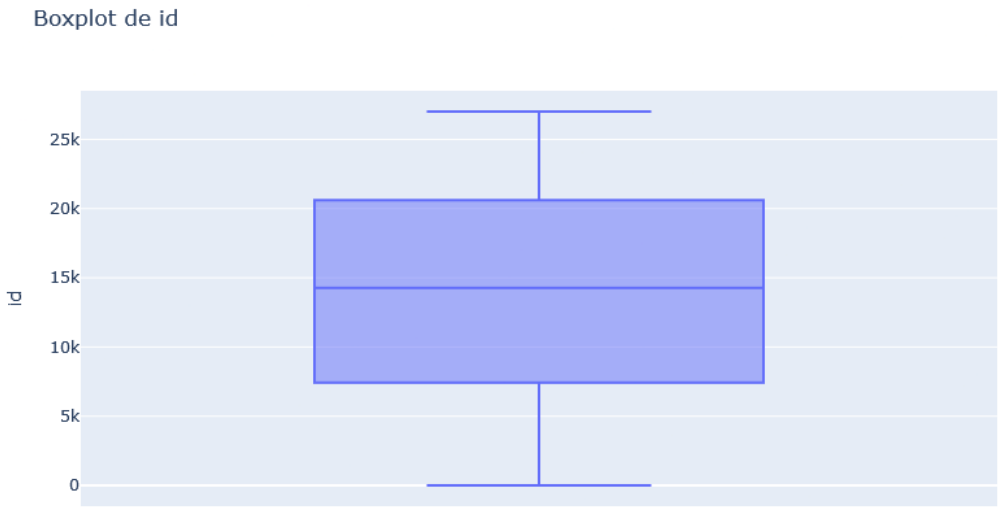

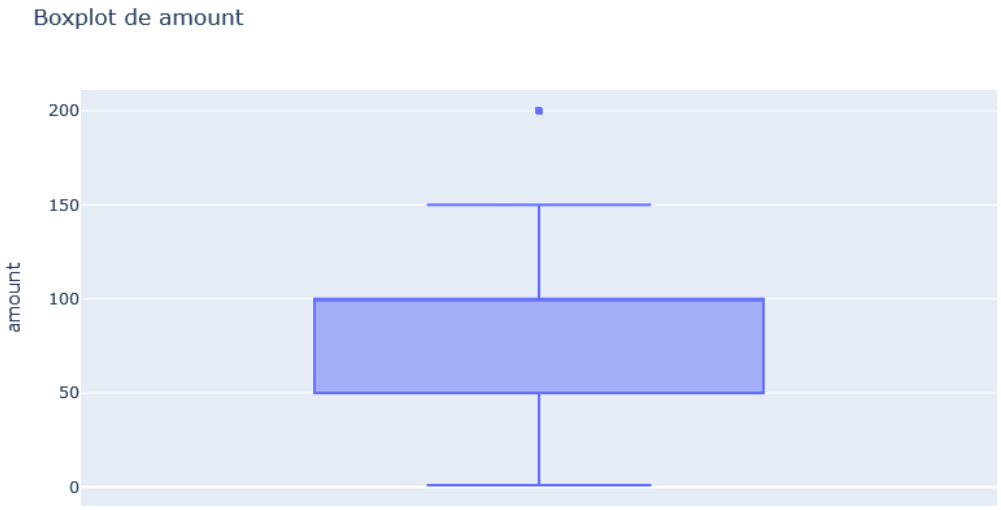

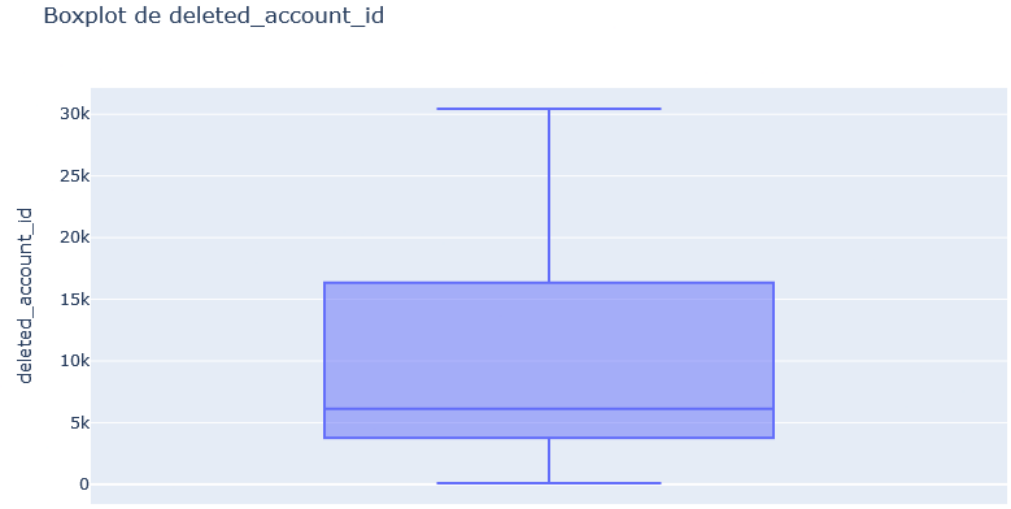

[16]:
```
for c in columnas_numericas_fees:
    fig = px.box(fees, y=c, title=f'Boxplot de {c}')
    fig.update_layout(height=500)
    fig.show()
```

Boxplot de id

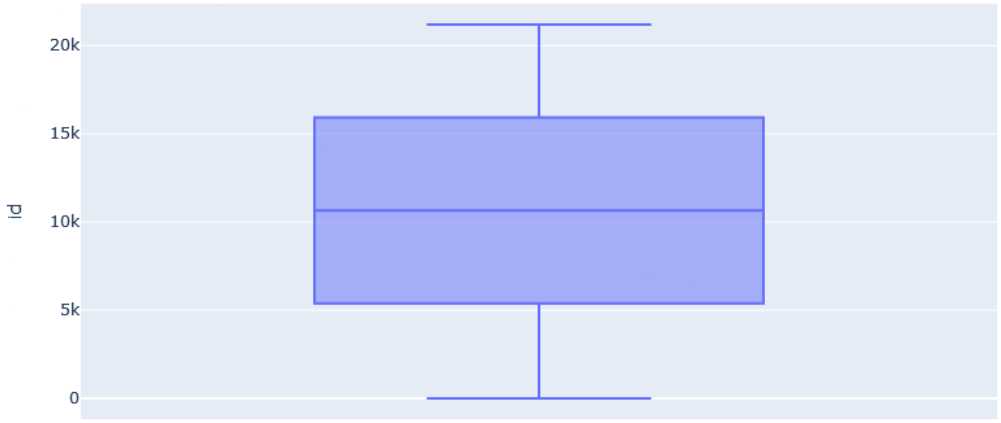

Boxplot de cash_request_id

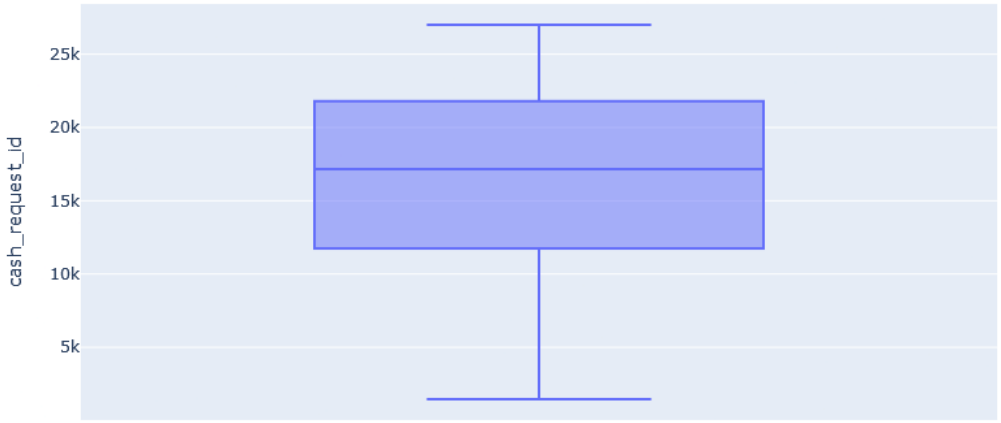

[17]:
```
for c in columnas_numericas_cash_request:
    fig = px.violin(cash_request, y=c, title=f'Violinplot de {c}')
    fig.update_layout(height=500)
    fig.show()
```

Violinplot de amount

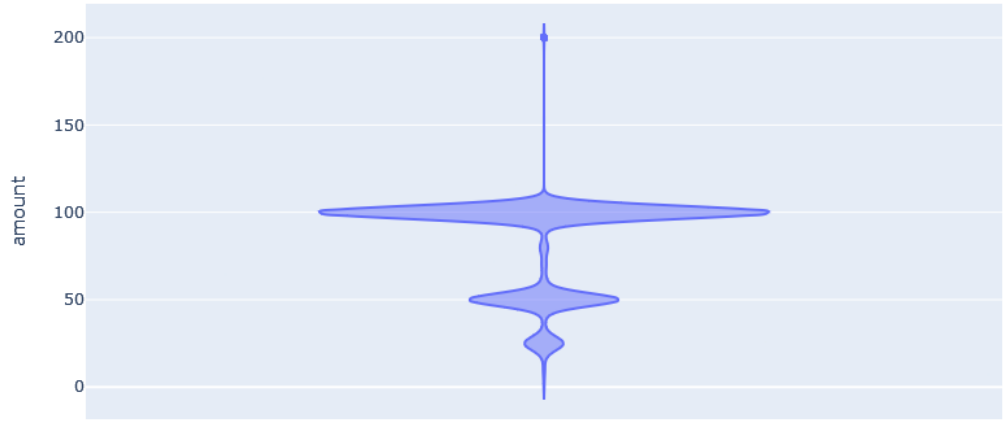

Violinplot de user_id

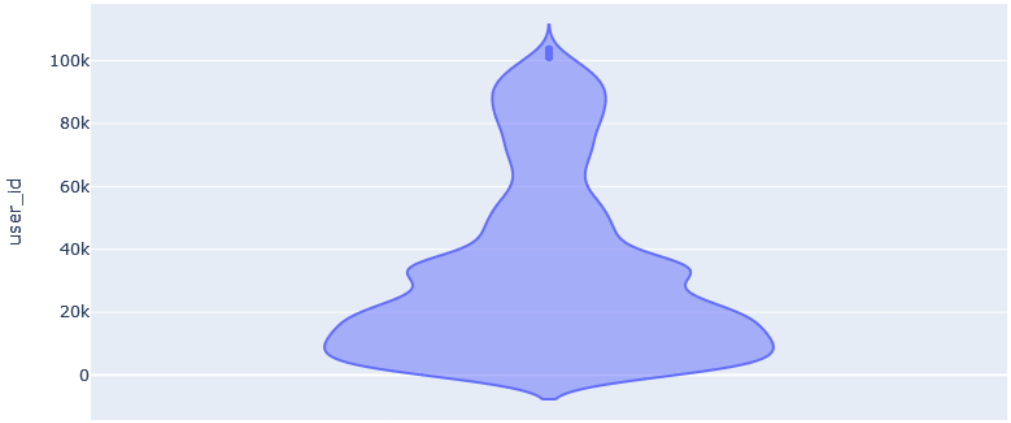

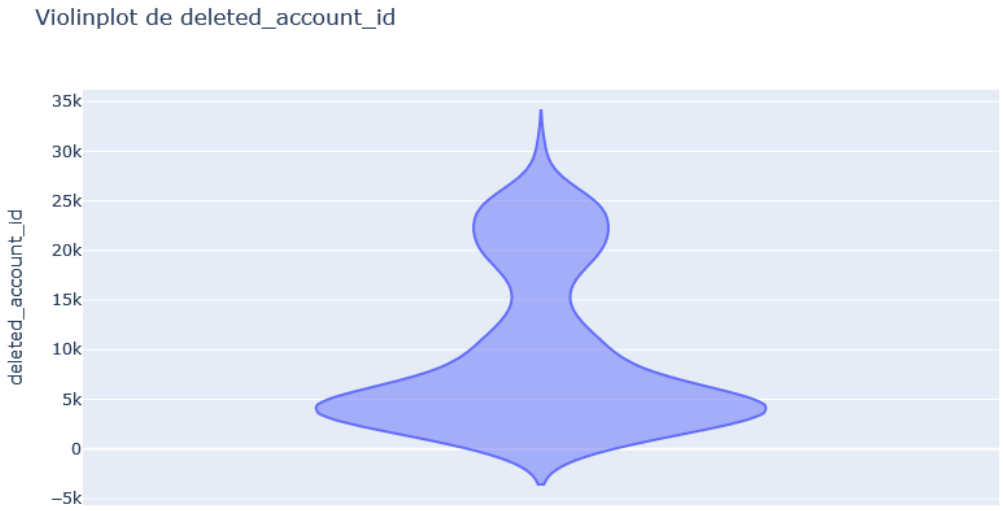

[18]:
```
for c in columnas_numericas_fees:
    fig = px.violin(fees, y=c, title=f'Violinplot de {c}')
    fig.update_layout(height=500)
    fig.show()
```

Violinplot de cash_request_id

Violinplot de total_amount

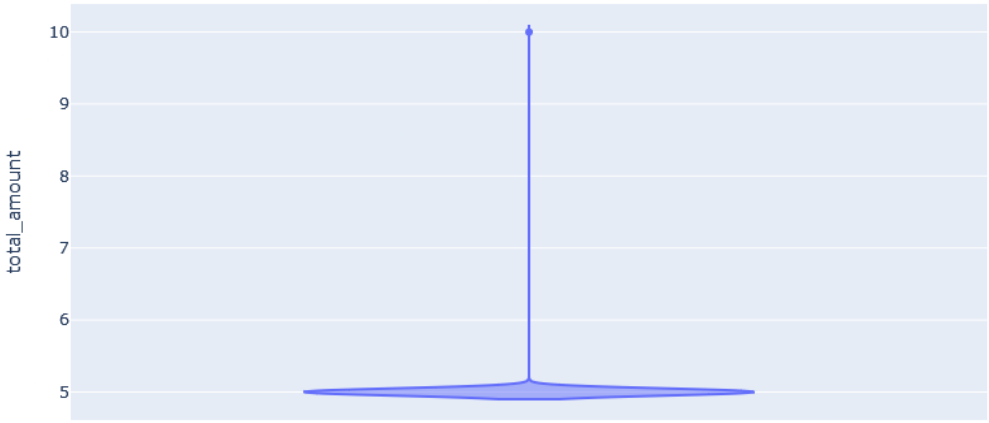

7 Obtener gráficos de dispersión

[19]:
```
# Genera gráficos de dispersión para todas las combinaciones de columnas␣
 ↪numéricas
for c1, c2 in itertools.combinations(columnas_numericas_cash_request, 2):
    fig = px.scatter(cash_request, x=c1, y=c2, title=f'Gráfico de dispersión de␣
 ↪{c1} vs {c2}')
    fig.update_layout(height=500)
    fig.show()
```

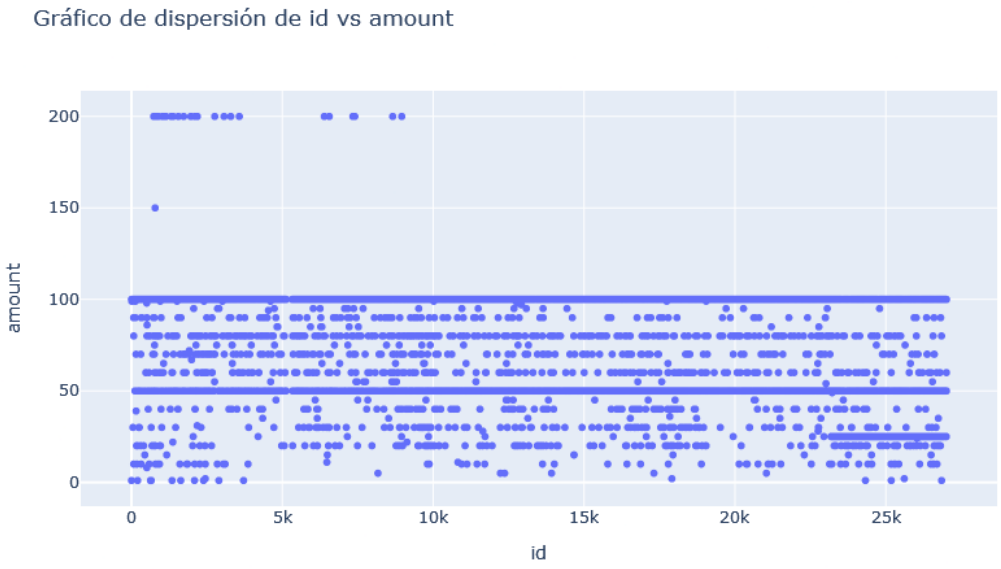

Gráfico de dispersión de id vs user_id

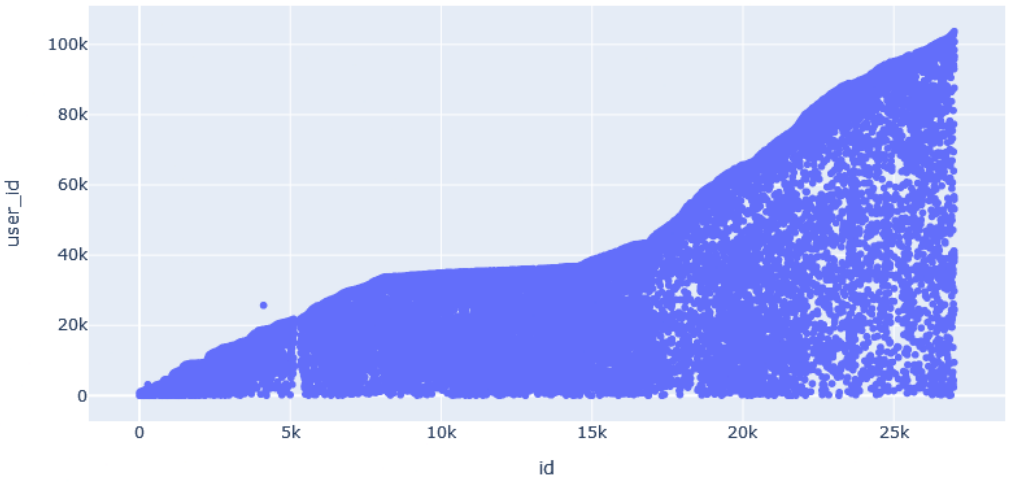

Gráfico de dispersión de id vs deleted_account_id

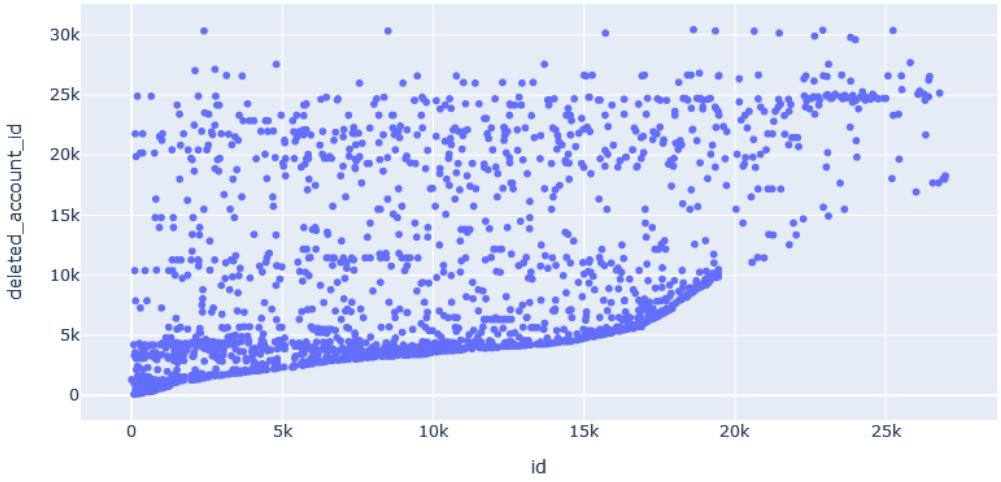

Gráfico de dispersión de amount vs user_id

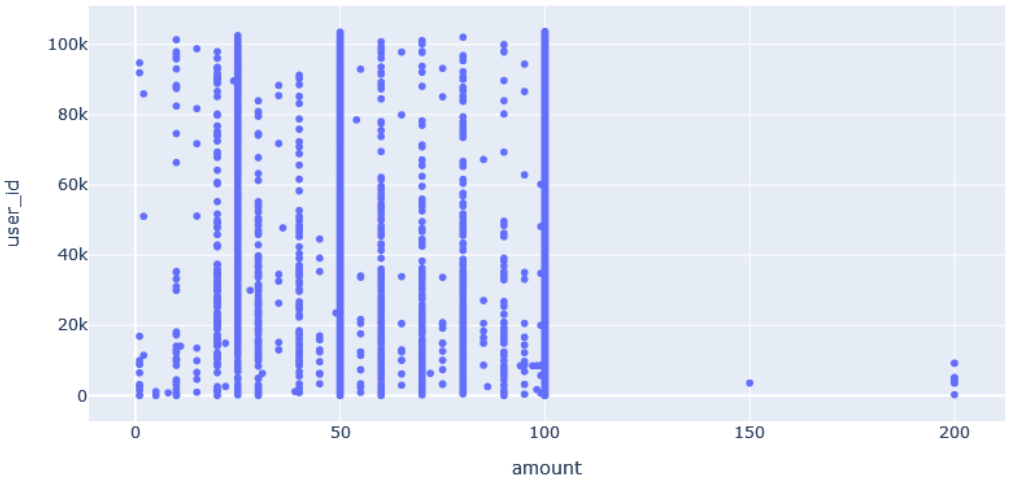

Gráfico de dispersión de amount vs deleted_account_id

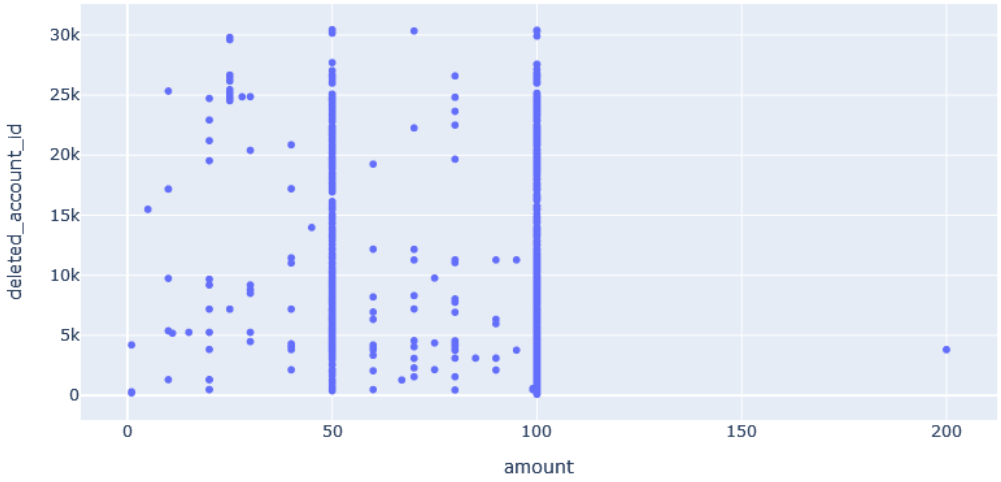

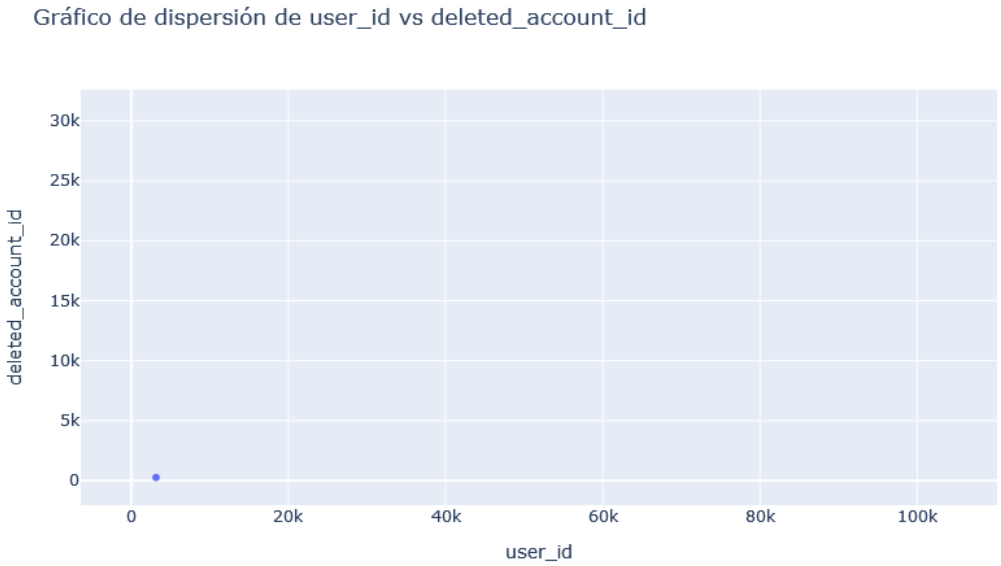

[20]:
```
# Genera gráficos de dispersión para todas las combinaciones de columnas␣
 ↪numéricas
for c1, c2 in itertools.combinations(columnas_numericas_fees, 2):
    fig = px.scatter(fees, x=c1, y=c2, title=f'Gráfico de dispersión de {c1} vs␣
 ↪{c2}')
    fig.show()
```

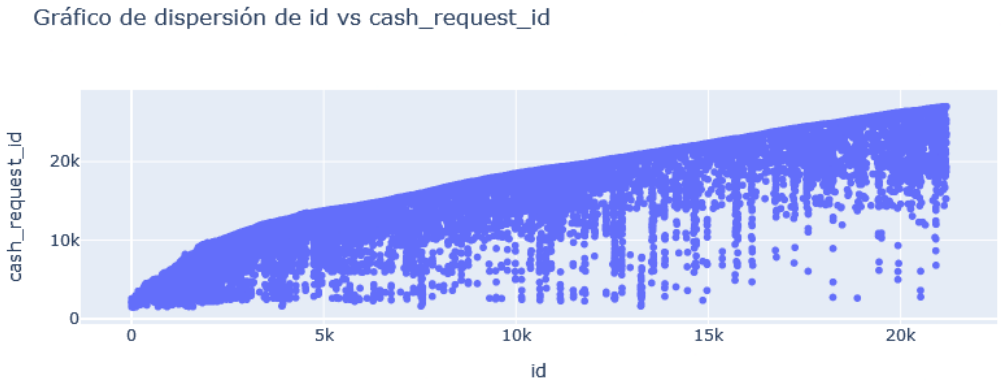

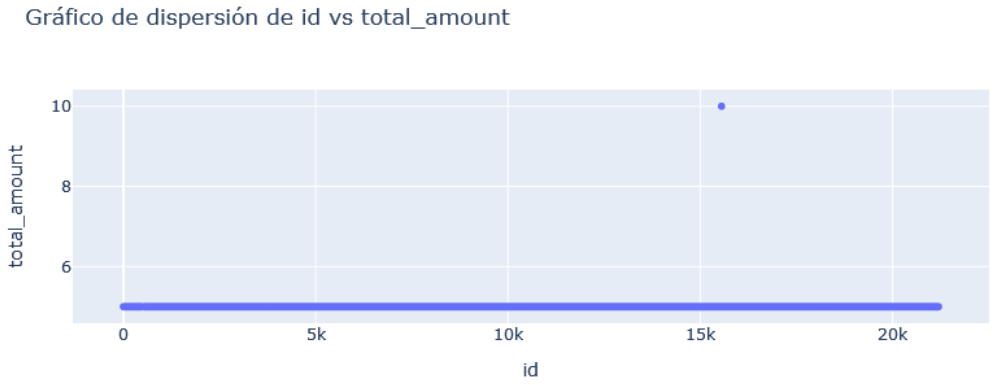

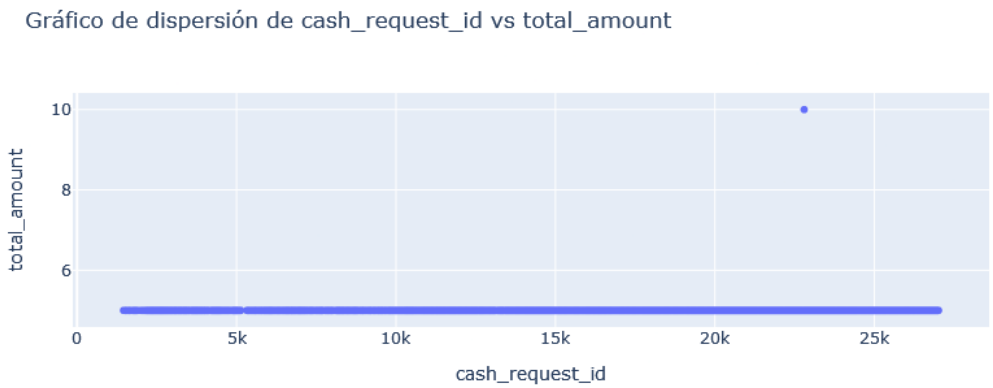

8 Obtener gráficos de dispersión con línea de regresión (Tendencia)

[21]:
```
# Genera gráficos de dispersión con línea de tendencia para todas las␣
 ↪combinaciones de columnas numéricas
for c1, c2 in itertools.combinations(columnas_numericas_cash_request, 2):
    fig = px.scatter(cash_request, x=c1, y=c2,
                     title=f'Gráfico de dispersión de {c1} vs {c2} con línea de␣
 ↪tendencia',
                     trendline="ols") # Agregar línea de tendencia (OLS)

    # Cambiar el color de la línea de tendencia a rojo
```

```
    fig.update_traces(line=dict(color='red', width=3))  # Color y ancho de la
↪línea de tendencia
    fig.update_traces(line=dict(color='red'), selector=dict(mode='lines'))  #
↪Cambiar el color de la línea de tendencia
    fig.update_layout(height=500)
    fig.show()
```

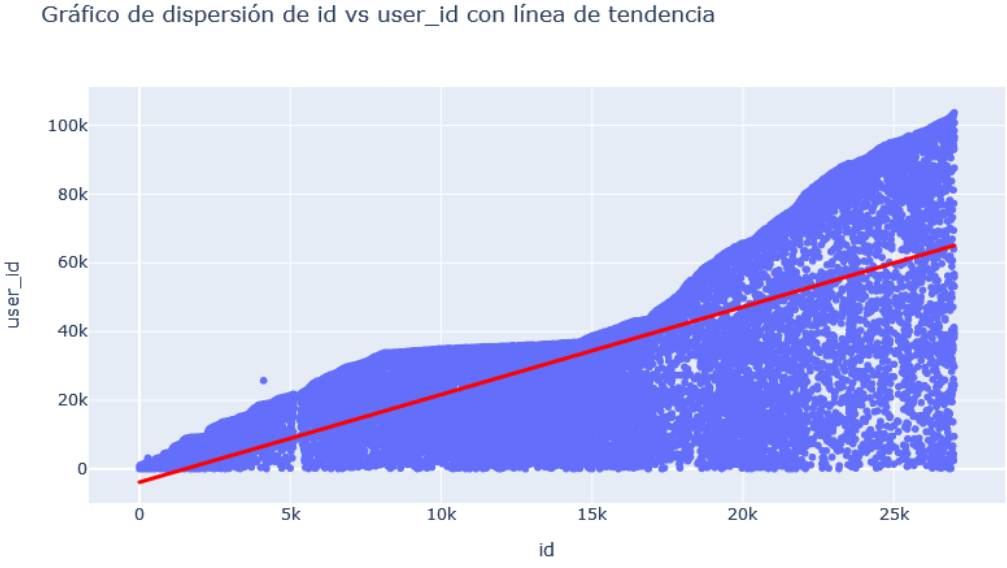

Gráfico de dispersión de id vs deleted_account_id con línea de tendencia

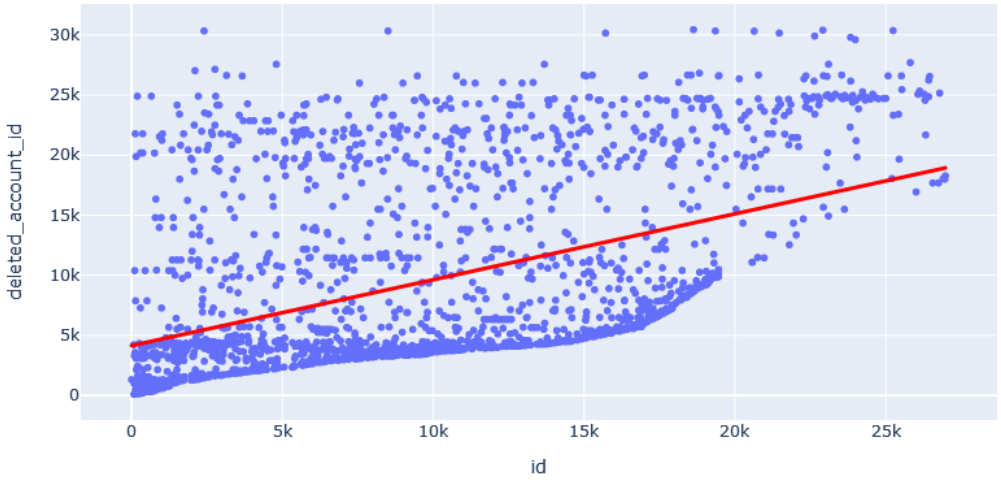

Gráfico de dispersión de amount vs user_id con línea de tendencia

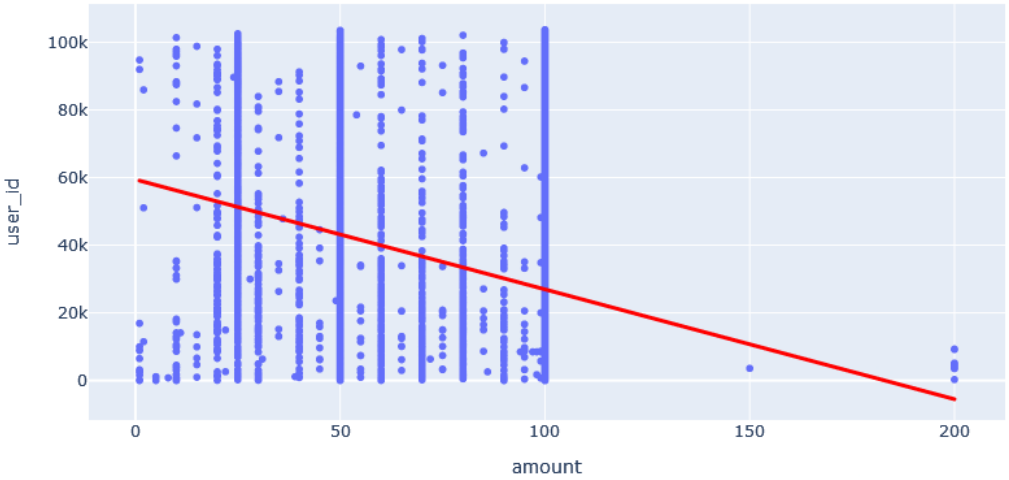

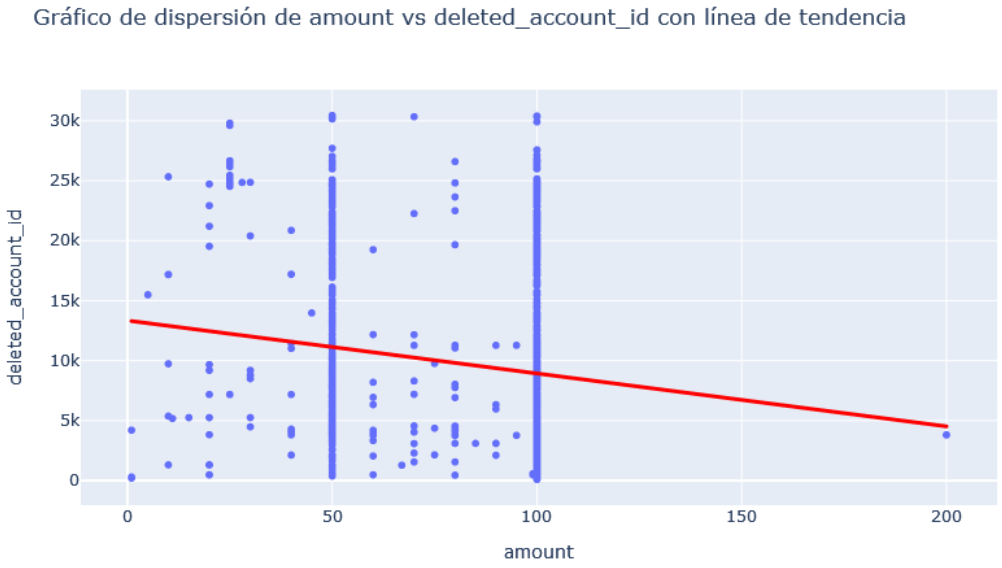

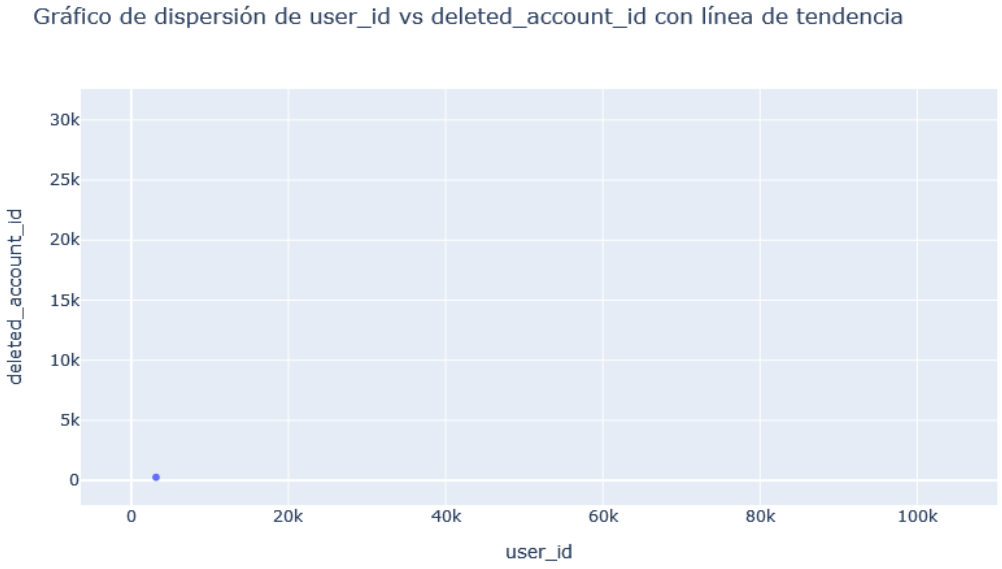

[22]:
```
# Genera gráficos de dispersión con línea de tendencia para todas las␣
 ↪combinaciones de columnas numéricas
for c1, c2 in itertools.combinations(columnas_numericas_fees, 2):
    fig = px.scatter(fees, x=c1, y=c2,
```

```
                    title=f'Gráfico de dispersión de {c1} vs {c2} con línea de␣
↪tendencia',
                    trendline="ols") # Agregar línea de tendencia (OLS)

    # Cambiar el color de la línea de tendencia a rojo
    fig.update_traces(line=dict(color='red', width=3))  # Color y ancho de la␣
↪línea de tendencia
    fig.update_traces(line=dict(color='red'), selector=dict(mode='lines'))  #␣
↪Cambiar el color de la línea de tendencia
    fig.update_layout(height=500)
    fig.show()
```

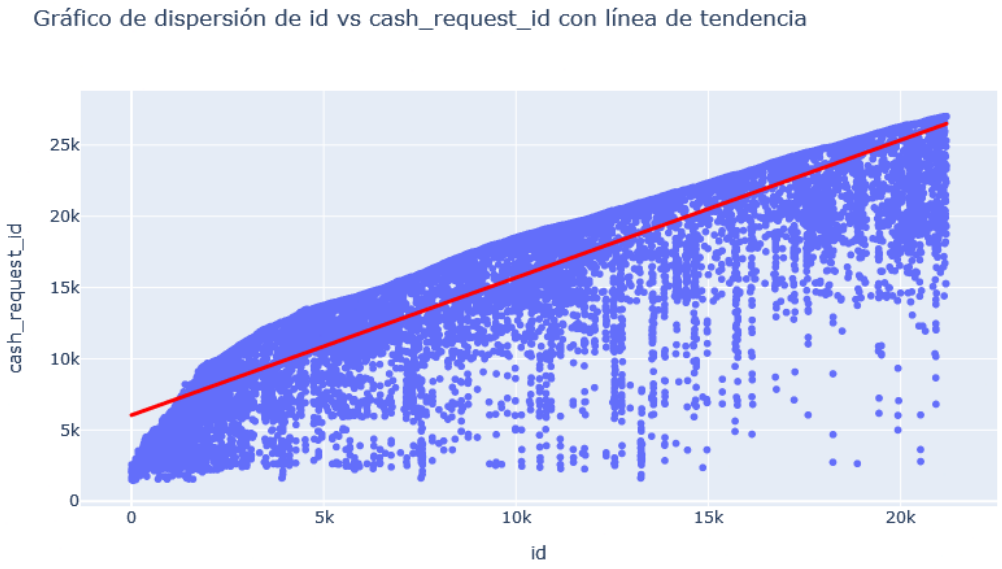

Gráfico de dispersión de id vs total_amount con línea de tendencia

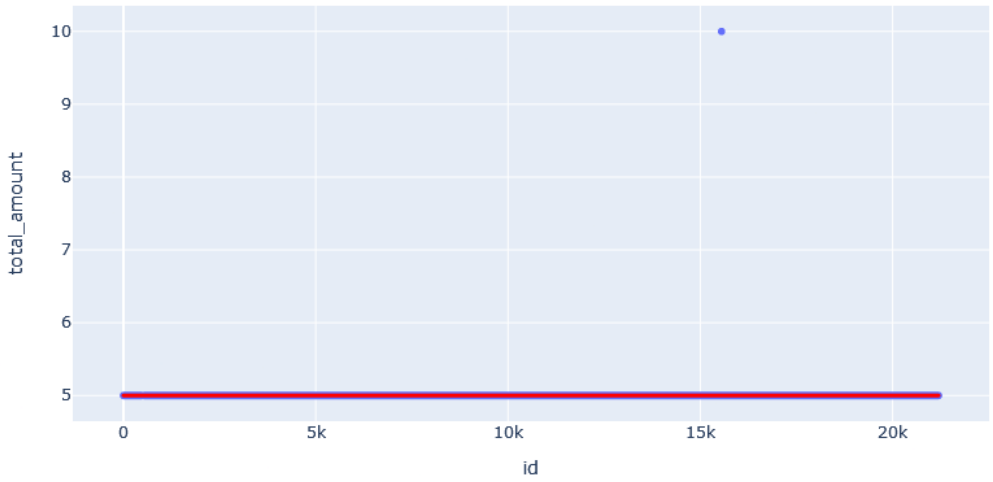

Gráfico de dispersión de cash_request_id vs total_amount con línea de tendencia

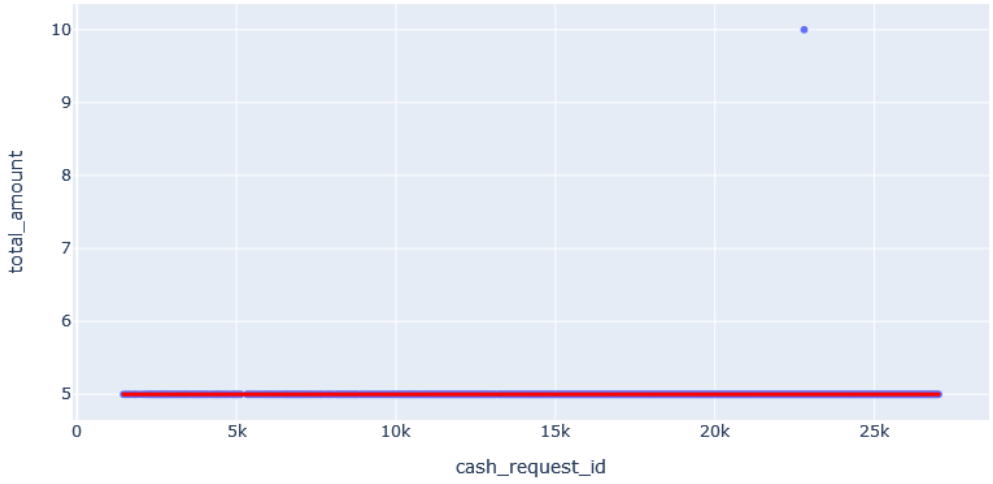

9 Obtencón de graficos en descomposición de serie temporal

9.0.1 ¿Qué es una serie temporal?

Una **serie temporal** es una secuencia de datos recolectados o registrados en momentos sucesivos, generalmente en intervalos uniformes de tiempo, como minutos, horas, días, meses o años. Este tipo de datos es fundamental para observar cómo un fenómeno cambia a lo largo del tiempo y se utiliza ampliamente en disciplinas como la economía, la meteorología, la salud pública, la ingeniería y las finanzas. Las series temporales son esenciales para el análisis de patrones, la identificación de tendencias y la elaboración de pronósticos, lo que permite una toma de decisiones más informada y efectiva.

Las series temporales suelen tener tres componentes principales:

1. **Tendencia (Trend)**:
   - La tendencia es el cambio a largo plazo en el nivel medio de la serie. Representa la dirección general en la que se están moviendo los datos a lo largo del tiempo y puede manifestarse de varias maneras:
     - **Ascendente**: Cuando los valores de la serie están aumentando de manera sostenida a lo largo del tiempo. Por ejemplo, el crecimiento en las ventas de un producto innovador que ha ganado popularidad con el tiempo.
     - **Descendente**: Cuando los valores están disminuyendo, como podría ser el caso de la venta de un producto obsoleto que ya no es relevante en el mercado.
     - **Estacionaria**: Cuando los valores fluctúan alrededor de un nivel constante sin mostrar una tendencia clara hacia arriba o hacia abajo.
   - Identificar la tendencia es fundamental para realizar pronósticos, ya que proporciona un contexto sobre el comportamiento general de la serie. Las técnicas utilizadas para detectar tendencias incluyen el uso de **medias móviles** (que suavizan las fluctuaciones) y **regresión lineal** (que ajusta una línea a los datos).
2. **Estacionalidad (Seasonal)**:
   - La estacionalidad se refiere a patrones que ocurren en intervalos regulares de tiempo, como días, meses o años, y que son predecibles. Esta variabilidad estacional suele ser el resultado de influencias cíclicas, como cambios en el clima o hábitos de consumo.
   - Por ejemplo, las reservas de hotel en una zona turística tienden a ser más altas en meses de verano (junio a agosto) debido a las vacaciones, mientras que pueden disminuir notablemente en invierno. Otro ejemplo podría ser la demanda de productos como ropa de abrigo, que aumenta en otoño e invierno y disminuye en primavera y verano.
   - Comprender la estacionalidad es crucial para ajustar pronósticos y prepararse para los cambios en la demanda que son previsibles, lo que permite a las empresas planificar mejor su producción y gestión de inventarios.
3. **Ruido (Residual o Noise)**:
   - El ruido es el componente que representa la variabilidad aleatoria o irregular en los datos que no se puede atribuir ni a la tendencia ni a la estacionalidad. Es una mezcla de factores imprevisibles y variaciones aleatorias que pueden influir en la serie temporal.
   - Este componente puede incluir eventos inusuales, como una crisis económica, un cambio repentino en la política gubernamental, o un fenómeno natural como un huracán que afecta la producción y distribución de bienes. También puede abarcar errores de medición y fluctuaciones inesperadas en los datos.
   - La presencia de ruido puede dificultar el análisis y la predicción de las series temporales,

ya que puede ocultar las señales de tendencia o estacionales. Por esta razón, es esencial realizar un análisis exhaustivo y aplicar técnicas como el **suavizamiento de datos** y la **eliminación de valores atípicos** para minimizar su impacto.

9.0.2 Importancia de la Descomposición

La descomposición de series temporales es un proceso que permite separar estos componentes (tendencia, estacionalidad y ruido) para un análisis más claro y efectivo. Al comprender cada uno de estos elementos, los analistas pueden tomar decisiones más informadas, mejorar la precisión de sus pronósticos y aplicar estrategias adaptadas a las condiciones observadas. Esta descomposición es particularmente útil en el ámbito empresarial para:

- **Planificar la producción**: Ajustando la capacidad de producción según las previsiones de demanda.
- **Gestionar inventarios**: Manteniendo niveles óptimos de stock para evitar faltantes o excesos.
- **Ajustar estrategias de marketing**: Llevando a cabo campañas promocionales en períodos de alta demanda estacional o lanzando nuevos productos en momentos estratégicos.

Entender y analizar series temporales es esencial para el éxito en un mundo donde los cambios son constantes y las decisiones deben basarse en datos concretos y patrones observados.

[23]:
```
# Descomposición de series temporales para cada columna numérica individual
for c in columnas_numericas_cash_request:
    # Crear una copia del DataFrame para trabajar
    cash_request_copy = cash_request[c].copy()

    # Verifica si hay valores faltantes y elimínalos o interpola
    if cash_request_copy.isnull().any():
        cash_request_copy = cash_request_copy.interpolate()  # Rellenar NaN con␣
↪interpolación

    # Eliminar filas con valores faltantes
    cash_request_copy = cash_request_copy.dropna()

    # Verificar que no hay valores no finitos
    if not np.isfinite(cash_request_copy).all():
        print(f'La columna {c} contiene valores no finitos, se omite la␣
↪descomposición.')
        continue

    # Descomposición de la serie temporal
    descomposicion = seasonal_decompose(cash_request_copy, model='additive',␣
↪period=12)

    # Graficar la descomposición
    fig = descomposicion.plot()

    # Ajustar el tamaño de la figura con matplotlib
```

```
    plt.gcf().set_size_inches(10, 6)

    # Ajustar el título para que no se superponga
    fig.suptitle(f'Descomposición de la serie temporal de {c}', fontsize=16,␣
↪y=1.05)
    plt.show()
```

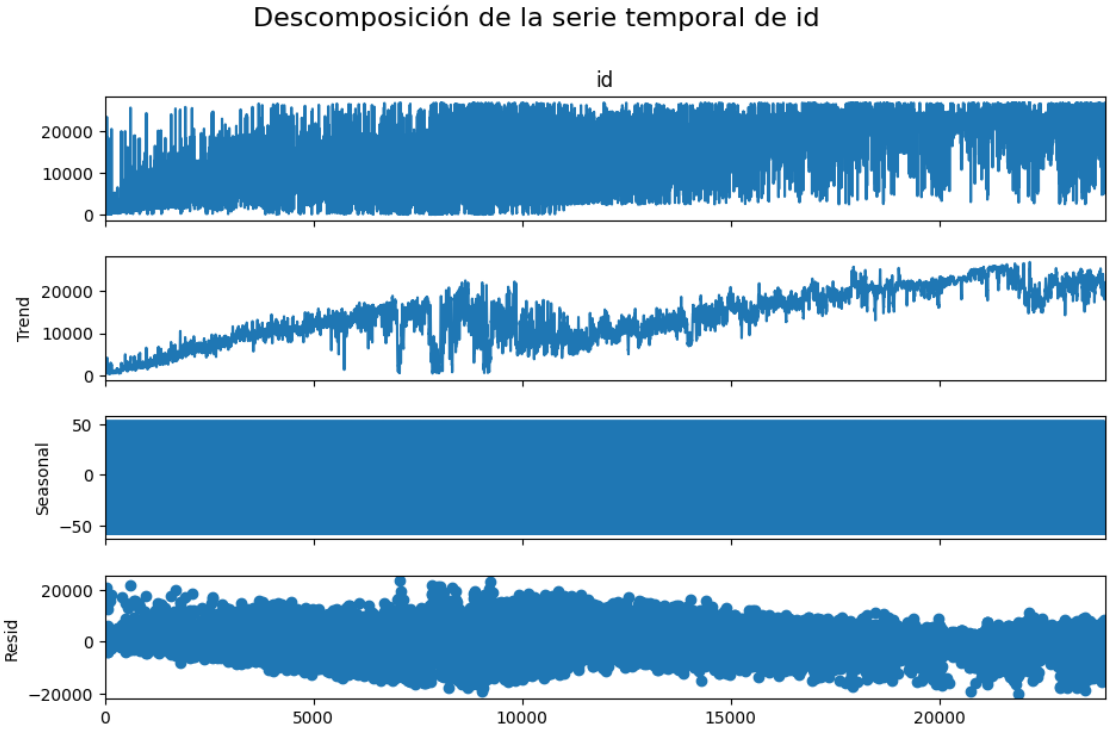

Descomposición de la serie temporal de amount

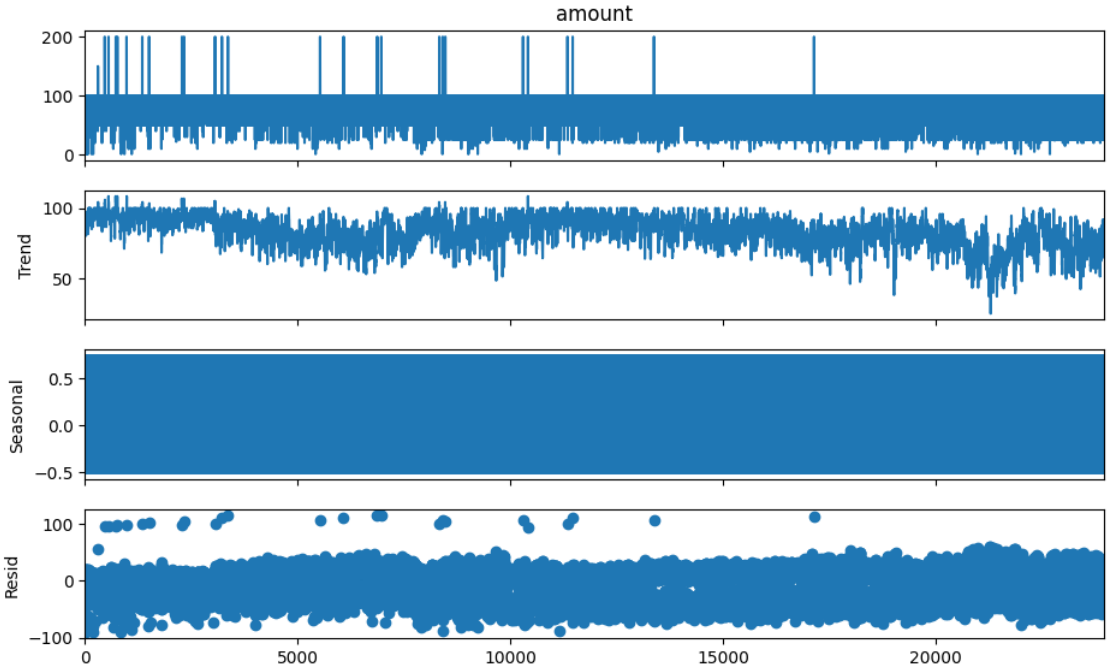

Descomposición de la serie temporal de user_id

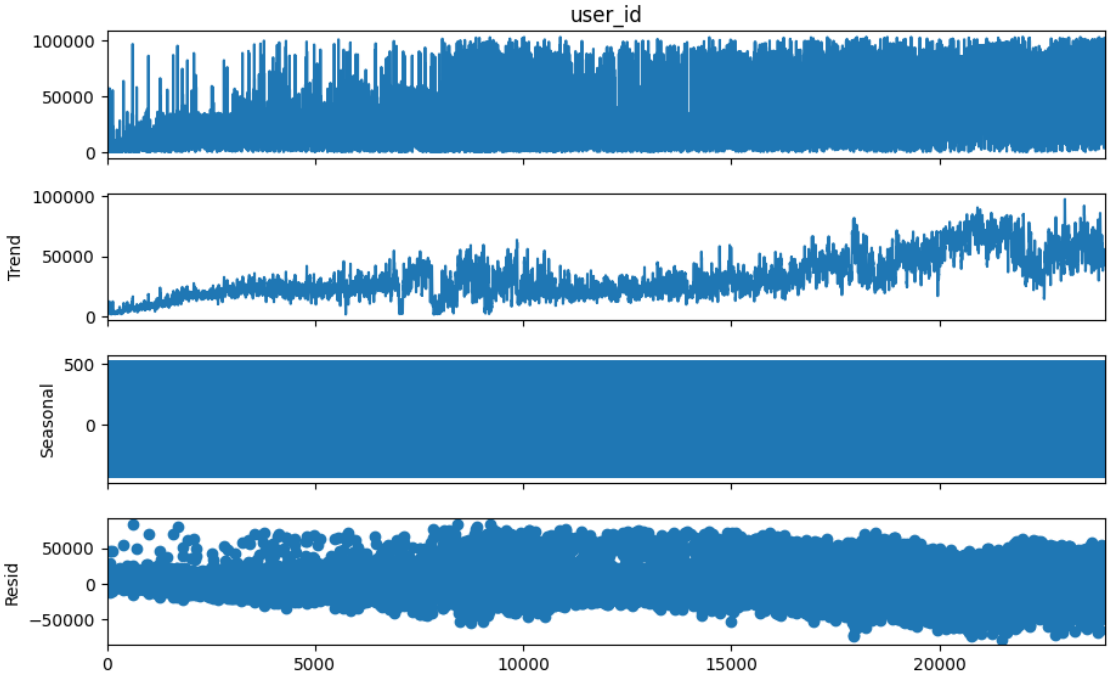

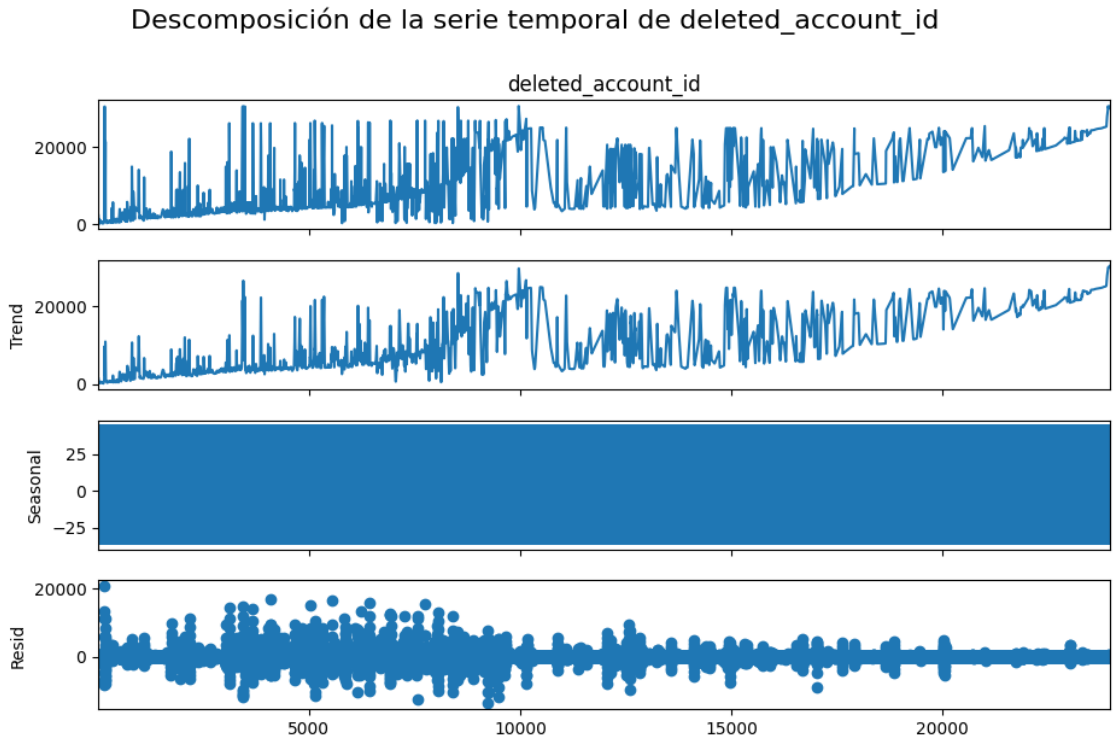

[24]:
```
# Descomposición de series temporales para cada columna numérica individual
for c in columnas_numericas_fees:
    # Crear una copia del DataFrame para trabajar
    fees_copy = fees[c].copy()

    # Verifica si hay valores faltantes y elimínalos o interpola
    if fees_copy.isnull().any():
        fees_copy = fees_copy.interpolate()  # Rellenar NaN con interpolación

    # Eliminar filas con valores faltantes
    fees_copy = fees_copy.dropna()

    # Verificar que no hay valores no finitos
    if not np.isfinite(fees_copy).all():
        print(f'La columna {c} contiene valores no finitos, se omite la␣
 ↪descomposición.')
        continue

    # Descomposición de la serie temporal
    descomposicion = seasonal_decompose(fees_copy, model='additive', period=12)

    # Graficar la descomposición
    fig = descomposicion.plot()
```

```
    # Ajustar el tamaño de la figura con matplotlib
    plt.gcf().set_size_inches(10, 6)  #

    # Ajustar el título para que no se superponga
    fig.suptitle(f'Descomposición de la serie temporal de {c}', fontsize=16,␣
↪y=1.05)

    plt.show()
```

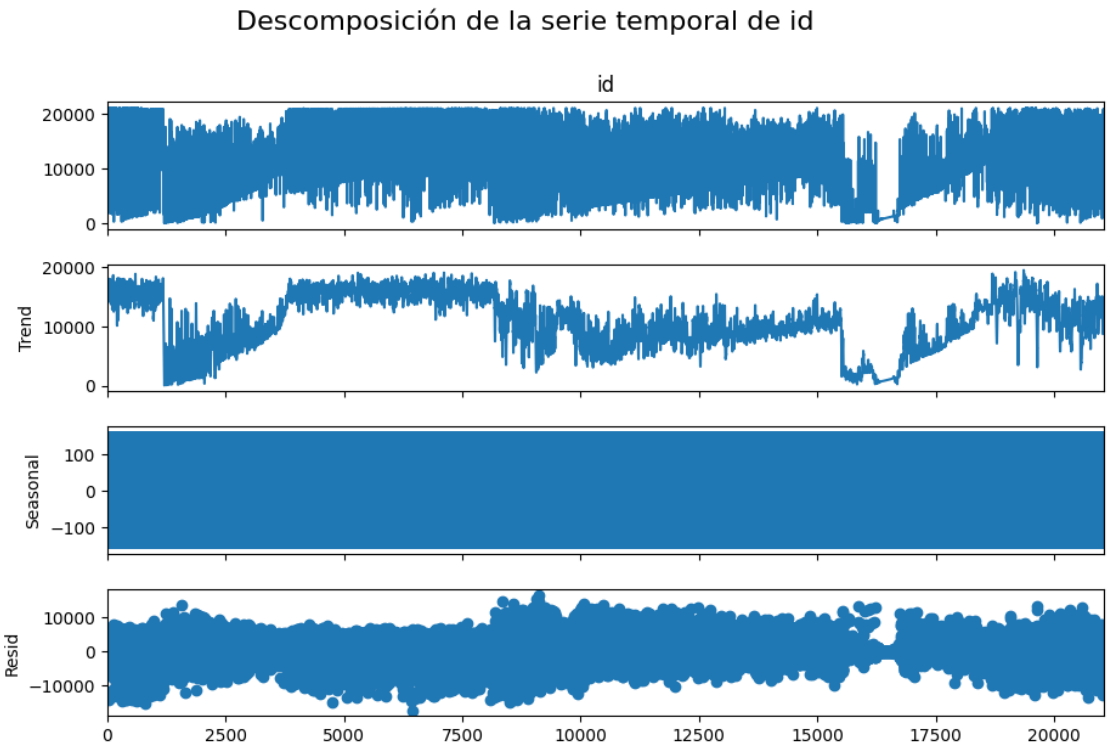

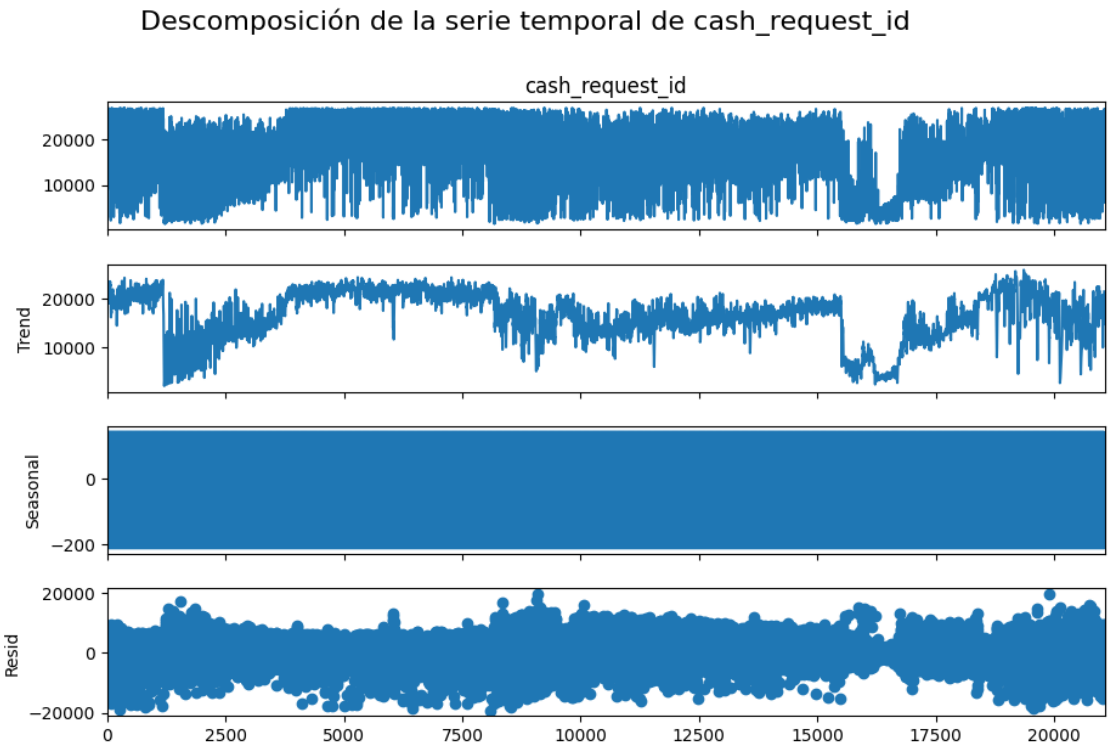
Descomposición de la serie temporal de cash_request_id
cash_request_id
Trend
Seasonal
Resid
20000
10000
0
−200
−20000
0
2500
5000
7500
10000
12500
15000
17500
20000

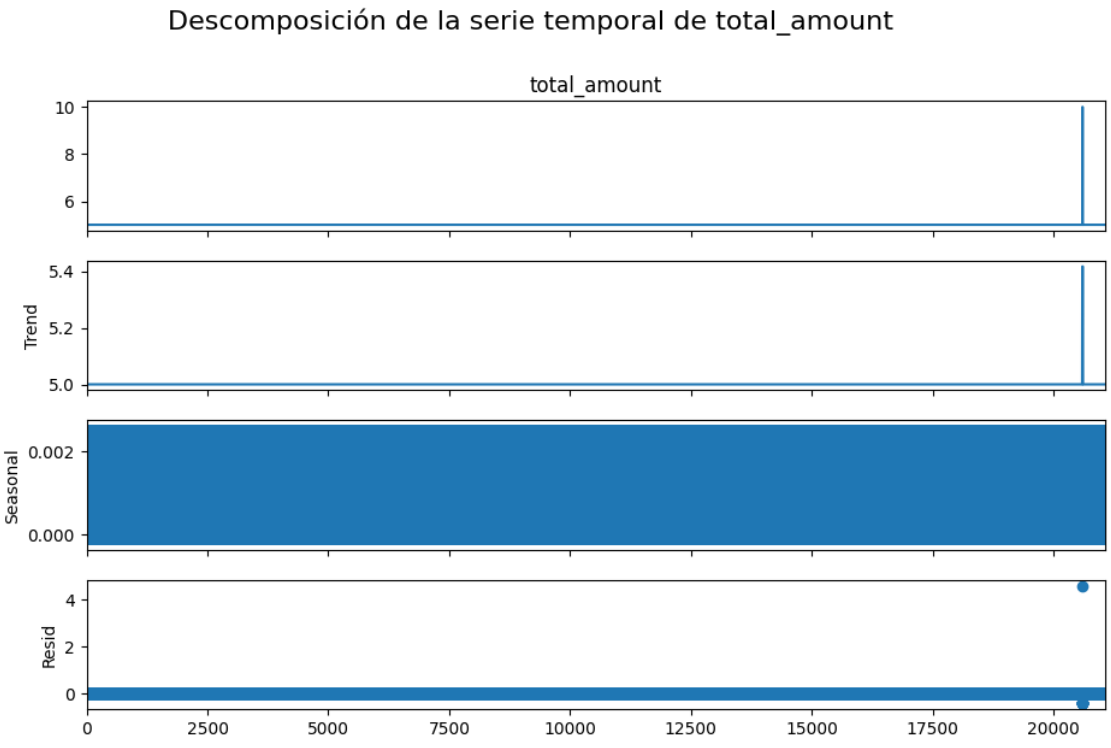
Descomposición de la serie temporal de total_amount
total_amount
Trend
Seasonal
Resid
10
8
6
5.4
5.2
5.0
0.002
0.000
4
2
0
0
2500
5000
7500
10000
12500
15000
17500
20000